

ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS

P00 - Predstavitev predmeta

Osebna izkaznica

predavatelj

asistent

red. prof. dr. Domen Mongus

dr. David Jesenko

02 220 74 08 

02 220 74 76

G2-2N.39 

G2-2N.11 - Weber

ponedeljek, 10-12h 

{domen.mongus, david.jesenko}@um.si

<http://gemma.feri.um.si/>, <https://estudij.um.si/>

Obveznosti študenta

□ 6 ECTS

- 30 ur predavanj
- 30 ur vaj
- 120 ur samostojnega dela

□ Ocena


- Izpit (50 %, obvezno vsaj 25 %)
- Vaje oz. projekt (50 %, obvezno vsaj 25 %)
- SKUPAJ (100 %; obvezno vsaj 50 %)

Priporočljiva literatura

- D. Mongus: [Interno gradivo \(na spletu\)](#)
- J. B. Campbell: Introduction to Remote Sensing, Fourth Edition, The Guilford Press, New York, 2008.
- L. Najman and T. Hugues: Mathematical morphology, John Wiley & Sons, Dublin, 2013.
- B. Khaleghi, A. Khamis, F. O. Karray, and S.N. Razavi: Multisensor data fusion: A review of the state-of-the-art. Information Fusion, 2013, 14(1), pp. 28-44.


Priporočljiva literatura

J. B. Campbell: Introduction to Remote Sensing, Fourth Edition, The Guilford Press, New York, 2008.



Priporočljiva literatura

L. Najman and T. Hugues:
Mathematical morphology,
John Wiley & Sons, Dublin,
2013.



Vsebina

- 1) Uvod
- 2) Tehnologije daljinskega zaznavanja
- 3) Osnove obdelave podatkov
 - 1) Arhitekturni in podatkovni modeli
 - 2) Tehnike obdelave podatkov (matematična morfologija)
 - 3) Podatkovno zlivanje
- 4) Aplikacije
 - 1) Razpoznave objektov

ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS

P01 – Kaj je daljinsko zaznavanje?

Vsebina

- 1) Osnovne definicije
- 2) Ključne tehnologije
- 3) Podatkovni modeli



Kaj je daljinsko zaznavanje?

- Pridobivanje informacij o objektih in pojavih brez fizičnega stika z njimi.

- Aplikacijska področja:
 - ▣ Geografijo in geodezijo
 - ▣ Zemeljske znanstvene discipline
 - hidrologija, ekologija, oceanografija, glacijologija, geologija);
ima tudi
 - ▣ Vojaške, obveščevalne aplikacije in humanitarne namene.
 - ▣ Gospodarske in načrtovalske

Stanje tehnike

- Sateliti
 - ▣ Leta 2014 = 192
 - ▣ Leta 2016 = 374
 - ▣ Leta 2018 = 684
 - ▣ Leta 2021 = 906
 - ▣ Leta 2022 = 1192
 - ▣ Od 2024 do 2033 = 5400 novih
- Letala
 - ▣ Vojaška tehnologija se seli v prakso
- Avtomobili
 - ▣ 3D skeniranja,
npr. google
- Ladje
 - ▣ Podvodna snemanja
- Podmornice
 - ▣ Sonar



Stanje tehnike

- Optičen zajem
 - ▣ Multi-spektralno
 - ▣ Hiper-spektralno
- 3D zajem
 - ▣ Sereovizija
 - ▣ Lasersko skeniranje
- Radar
 - ▣ Radio signali
- Sonar
 - ▣ Zvok



Terrestrial and Mobile scanning




Ključni metapodatki

- Podatki daljinskega zaznavanja so georeferencirani
 - ▣ Določen koordinatni sistem in položaj vsake merjene točke
- Parametri meritev
 - ▣ Prostorska ločljivost – dejanska razdalja med dvema točkama ...
 - Na primer velikost piksla na satelitski sliki je lahko 10m.
 - ▣ Časovna ločljivost – frekvenca zajema podatkov
 - Na primer Sentinel 2 zajame podatke vsake 5-8 dni
 - ▣ Spektralna ločljivost – širina spektralnih pasov
 - Na primer Landsat snema IR pas v 0.7 do 2.1 μm
 - ▣ Radiometrična ločljivost – koliko bitov porabimo za en zapis

Ključni metapodatki

- Koordinatni sistemi so določeni z elipsoidi
 - ▣ Geodetski datum je referenčna točka, glede na katero merimo vse ostale točke:
 - Določa izhodišče, orientacijo, velikost,...
 - ▣ Zemlja je geoid:





- Posledično imamo množico koordinatnih sistemov



Ključni metapodatki

□ Projekcije:


▣ Konusne:




▣ Cilindrične:



▣ Azimutne:



Ortografska



Ključni metapodatki

- Azimutne
 - ▣ Ortografska (letalo)




Ključni metapodatki

- Azimutne
 - ▣ Ortografska (Airbus – SPOT 6)




Osnove obdelave

- Georeferenciranje
 - ▣ Podatke lahko zlagamo enega na drugega
 - ▣ Meritve v fizikalnih enotah, npr. meter, kvadratni meter, ...
- Komplementarne meritve
 - ▣ Modeli zlivanja (ang. data fusion)



Osnove obdelave

- Splošna orodja
 - ▣ Matematična morfologija
 - ▣ Analiza teksture
 - ▣ Geometrijski (oblikovni) vzorci
- Orodja, odvisna od podatkovnega tipa:
 - ▣ Spektralna analiza (optika)
 - ▣ Frekvečna analiza (radar)
 - ▣ Geometrija (3D skeniranje)



Običajni izzivi...

- Razpoznava objektov:
 - ▣ Hiše, ceste, gozdovi, reke, ladje, ...
- Razpoznave procesov:
 - ▣ Zaraščanje travnikov, suša, zemeljski plazovi, rast begunskih kampov, ...
- Izračun statistik:
 - ▣ Število prebivalcev, površina gozdov, škoda ob suši, ...
- Napovedovalne analize:
 - ▣ V kombinaciji z GIS, požarna ogroženost, poplavna ogroženost, ...


ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS

Vsebina

- Teoretične osnove - elektromagnetna energija
- Osnove (multi-) hiperspektralnega slikanja
- Spektralna diferenciacija

Elektromagnetna energija




Elektromagnetni spekter

Elektromagnetna energija

☐ Porazdelitev sončne energije po spektru


Spektralna regija	Valovna dolžina [mm]	% celotne energije
žarki gama in X	$< 0,01$	zanemarljivo
daljna UV	$0,01 - 0,2$	0,15
srednja UV	$0,2 - 0,3$	3,10
bližnja UV	$0,3 - 0,4$	9,14
vidna svetloba (V)	$0,4 - 0,7$	36,80
bližnja IR (NIR)	$0,7 - 1,1$	27,60
kratkovalovna IR (SWIR)	$1,1 - 3,0$	21,10
srednja IR (MWIR)	$3,0 - 5,6$	1,72
termična (dolgovalovna) IR (LWIR)	$5,6 - 1000$	0,38
mikrovalovi	$> 1 \text{ mm}$	0,02
radijski valovi	$> 1 \text{ m}$	zanemarljivo

Vzorčenje spektra




LOW

pankromatsko: en sam zelo širok pas




MED

multispektralno: nekaj pa do nekaj 10 pasov




HIGH

hiperspektralno: na stotine ozkih pasov



Pasivni in aktivni senzorski sistemi






- Pasivni senzorski sistemi izvajajo meritev energije okolice
 - ▣ to je energije, ki je v okolju že prisotna in je ne ustvari merilna naprava

- Aktivni senzorski sistemi sondiranjem okolja z lastno energijo.
 - ▣ Merilna naprava pošlje energijo v okolico in izmeri odziv




Sentinel 2

- Sončno sinhrona orbita:
 - ▣ Vsaka točka na zemlji je izmerjena v istem solarnem času
 - ▣ Čez Evropo, Afriko ter Indijo...
- Spektralni pasovi:
 - ▣ Vidni spekter in NIR (10m):






Sentinel 2

- Sončno sinhrona orbita:
 - ▣ Vsaka točka na zemlji je izmerjena v istem solarnem času
 - ▣ Čez Evropo, Afriko ter Indijo...
- Spektralni pasovi:
 - ▣ Vegetation edges (20 m):



Sentinel 2

- Sončno sinhrona orbita:
 - ▣ Vsaka točka na zemlji je izmerjena v istem solarnem času
 - ▣ Čez Evropo, Afriko ter Indijo...
- Spektralni pasovi:
 - ▣ Izhlapevanje vode... (60 m):




PRIMER: Blejsko jezero

- Band 1:
 - ▣ Ločljivost 60m
 - ▣ Ultravijolična (443 nm)
 - ▣ Plitke obale in aerosol (prah)



PRIMER: Blejsko jezero

- Band 2:
 - ▣ Ločljivost 10m
 - ▣ Modra (490 nm)



PRIMER: Blejsko jezero

- Band 3:
 - ▣ Ločljivost 10m
 - ▣ Zelena (560 nm)




PRIMER: Blejsko jezero

- Band 4:
 - ▣ Ločljivost 10m
 - ▣ Rdeča (665 nm)




PRIMER: Blejsko jezero

- Band 5:
 - ▣ Ločljivost 20m
 - ▣ NIR (705 nm)
 - ▣ Prvi vegetacijski rob




PRIMER: Blejsko jezero

- Band 6:
 - ▣ Ločljivost 20m
 - ▣ NIR (740 nm)
 - ▣ Drugi vegetacijski rob




PRIMER: Blejsko jezero

- Band 8:
 - ▣ Ločljivost 10m
 - ▣ NIR (842 nm)
 - ▣ NDVI




PRIMER: Blejsko jezero

- Band 8A:
 - ▣ Ločljivost 20m
 - ▣ NIR (865 nm)
 - ▣ Četrtri
vegetacijski rob



PRIMER: Blejsko jezero

- Band 9:
 - ▣ Ločljivost 60m
 - ▣ NIR (940 nm)
 - ▣ Izhlapevanje vode




PRIMER: Blejsko jezero

- Band 10:
 - ▣ Ločljivost 60m
 - ▣ SWIR (1375 nm)
 - ▣ Zaznava oblakov




PRIMER: Blejsko jezero

- Band 11:
 - ▣ Ločljivost 20m
 - ▣ SWIR (1610 nm)
 - ▣ Zaznava oblakov




PRIMER: Blejsko jezero

- Band 1 2:
 - ▣ Ločljivost 20m
 - ▣ SWIR (2190 nm)
 - ▣ Vlažnost tal (sneg in led)




Osnove HSI

- HSI = hyperspectral imaging
 - ▣ merjenje energije v območju vidne (V) pa vse do dolgovalovne IR (LWIR) elektromagnetnega spektra
 - ▣ vsaka meritev zajema energijo v ozkem pasu valovnih dolžin
 - ▣ razmerje med odbito in sevano energijo pri različnih valovnih dolžinah različno, zato se istoležni piksli v posameznih slikah (kanalih) razlikujejo




HSI slikovna kocka

- Hiperspektralne slike pogosto prikazujemo v obliki HSI slikovne kocke – npr. AVIRIS (NASA) HSI Image Cube
 - Na vrhu rezina z najmanjšo valovno dolžino (400 nm)
 - Tipično 220 (tudi 224) kanalov s po 12 biti na vzorec
 - $2^{220 \cdot 12} = 2^{2640} \sim 10^{795}$ različnih “barvnih” odtenkov
- Barvni odtenek oz. vektor meritev za posamezen piksel je **spektralni podpis** (spectral signature) piksla
- Različni spektralni podpisi zrcalijo različne lastnosti materialov v različnih (npr. vremenskih) razmerah.
- Primer:
 - Desno zgoraj precej rdeče (kolonija rakov)
 - Stolpci spektralni podpisi robnih pikslov





Spektralni podpis

Primerjava spektralnih podpisov različnih materialov



Osnove HSI

- ▣ Spektralni podpisi beleženi v knjižnicah
- ▣ Na tisoče zapisov v takšni knjižnici za identifikacijo materialov
- ▣ Predstavitev
 - N-Dimenziionalen prostor točk (vzorcev)




Primerjava spektralnih podpisov

□ Evklidska razdalja v n-D hiperprostoru

▣ vsak spektralni podpis je točka v n-D hiperkocki s stranico $2^{12} = 4096$ (če imamo 12 bitov na meritev)

▣ evklidska razdalja med $s_1 = (s_{1,1}, s_{1,2}, \dots, s_{1,n})$ in $s_2 = (s_{2,1}, s_{2,2}, \dots, s_{2,n})$ je:

$$d(s_1, s_2) = \sqrt{\sum_{i=1}^n (s_{2,i} - s_{1,i})^2}$$




▣ Zaradi prekletstva dimenzionalnosti pogosta uporaba PCA!

Primerjava spektralnih podpisov

- Metrika kotne razdalje (spectral angle mapper; SAM)
 - ▣ kot med krajevnima vektorjema dveh spektrov
 - ▣ manjši kot pomeni večjo podobnost med spektroma

$$\theta(s_1, s_2) = \arccos \frac{s_1 \cdot s_2}{\|s_1\| \|s_2\|}$$




Tradicionalen pristop k klasifikaciji ...

□ Poljuben tradicionalni klasifikator




Naporen pristop k klasifikaciji ...

- Vključuje učenje značilk



Leni pristop k klasifikaciji ...

□ Klasifikacija KNN



KNN kot klasifikator

□ Kakšna naj bo vrednost K?


▣ Zakaj ne vedno 1?

▣ Zakaj ne vedno ∞ ?


□ Kako določiti rezultat?

▣ Pričakovana vrednost
ali povprečje?

▣ Uteži glede na
razdalje?




Elektromagnetna energija



Elektromagnetna energija

- Vpadna sončna energija (100 %) se porazdeli:
 - ▣ 6 % se odbije od atmosfere
 - ▣ 20 % se odbije od oblakov
 - ▣ 4 % se odbije od zemeljskega površja
 - ▣ 16 % absorbira atmosfera
 - ▣ 3 % absorbirajo oblaki
 - ▣ 51 % absorbirajo kopno in morja.
- Zemlja, oblaki in atmosfera sčasoma oddajo v vesolje vso absorbirano energijo
 - ▣ Zemlja deloma direktno, deloma preko oblakov in atmosfere (toplotno prevajanje, izhlapevanje vode)


Odbita in sevana energija



Krajši valovi se odbijajo, daljši absorbirajo in nato žarčijo, pri MWIR meja (oba načina)

Enak princip tudi ob upoštevanju atmosfere in oblakov

Interakcija energije in objektov



V enačbi ni E_e , saj gre le za z zamikom sevano E_a .

Primerjava spektralnih podpisov

- Odvisna od svetlobnih pogojev pod katerimi je zajeta slika
- Kakšna je svetloba v sencah?




Spektralna diferenciacija

□ PRIMER:

- ▣ NDVI – normalized difference vegetation index

$$NDVI = \frac{(NIR - VIS)}{(NIR + VIS)}$$

- ▣ Rastline absorbirajo energijo, ki jo uporabljajo za fotosintezo
- ▣ Svetlobe nad 700nm niso zmožne sintetizirati organskih molekul
- ▣ Rastline so zato temne pri krajših valovnih dolžina in svetle pri daljših



Spektralna diferenciacija

Za slike Sentinel 2

Band name	Resolution [m]	Central wavelength [nm]	Band width [nm]
1	60	443.9	27
2	10	496.6	98
3	10	560.0	45
4	10	664.5	38
5	20	703.9	19
6	20	740.2	18
7	20	782.5	28
8	10	835.1	145
8a	20	864.8	33
9	60	945.0	26
10	60	1373.5	75
11	20	1613.7	143
12	20	2202.4	242

Name	Definitions
Enhanced vegetation index	$EVI = \frac{\overline{s}[8] - \overline{s}[4]}{\overline{s}[8] + 6\overline{s}[4] - 7.5\overline{s}[2] + 1}$
Normalised difference vegetation index	$NDVI = \frac{\overline{s}[8] - \overline{s}[4]}{\overline{s}[8] + \overline{s}[4]}$
Green normalised difference vegetation index	$GNDVI = \frac{\overline{s}[8] - \overline{s}[3]}{\overline{s}[8] + \overline{s}[3]}$
Moisture stress index	$MSI = \frac{\overline{s}[11]}{\overline{s}[8]}$
Normalised difference water index	$NDWI = \frac{\overline{s}[3] - \overline{s}[11]}{\overline{s}[3] + \overline{s}[11]}$
Normalised difference built-up index	$NDBI = \frac{\overline{s}[11] - \overline{s}[8]}{\overline{s}[11] + \overline{s}[8]}$
Normalised difference mud index	$NDMI = \frac{\overline{s}[9] - \overline{s}[8]}{\overline{s}[9] + \overline{s}[8]}$

Obdelava podatkov

„Pixel based“

- Nizka prostorska ločljivost
- Visoka spektralna ločljivost
- Generiranje značilnic v okolici piksla (okno)
 - ▣ Konvolucija
 - ▣ Teksturna analiza

„Object based“

- Visoka prostorska ločljivost
- Nizka spektralna ločljivost
- Segmentacija in značilnice regij
 - ▣ Matematična morfologija
 - ▣ LoFS, ...

ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS

Vsebina

- Uvod v tematiko
- Povezljivost
- Definicija operatorja
- Izpeljava osnovnih operatorjev

POZOR: V tem okviru bomo obravnavali smiseln nivo generalizacije! Uporabljene notacije bodo prilagojene za namene naše uporabe in ne bodo skladne z zelo splošnimi koncepti, kot koncepti teorije mrež, povezanost druge generacije in podobno. Podane notacije so zato lahko drugačne kot jih najdete npr. na wikipediji.


Osnovni pojmi

- Morfologija
 - ▣ Oblikoslovje ozirom analiza forme in oblike
- Matematična morfologija
 - ▣ Uporablja matematična orodja za analizo oblik
 - ▣ Skoncentrirana na prostorske vzorce
 - ▣ Slabi rezultati na časovnih vrstah




MM v procesu OPDZ


□ Nizkonivojska obdelava podatkov



Primer izrazne moči MM




Primer izrazne moči MM



Nizkonivojska obdelava podatkov – Predobdelava z morfološkimi filtri


- Izločanje regij glede na velikost




- Odstranjevanje osvetlitve




- Zaznava robov



- Izločanje regij glede na obliko




- Odstranjevanje šuma




Nizkonivojska obdelava podatkov – Morfološka segmentacija


- Algoritem razvodja



- Ločevanje povezanih objektov




- Gručenje





Nizkonivojska obdelava podatkov – Izdvajanje značilnic


- Diferencialni profili



- Spektri vzorcev



- Transformacija razdalj



Teoretično ozadje

- **Univerzalni prostor E^D** , kjer D določa dimenzionalnost prostora
 - ▣ $D = 1$ če obdelujemo tradicionalne signale
 - ▣ $D = 2$ primeren za obdelavo 2 in 2.5 D podatkov,
 - ▣ $D = 3$ opisuje vokselske podatke...
- **Diskretni prostor $P \subseteq E^D$** določa mrežo, kjer $P = \{p_i\}$:
 - ▣ p_i je piksel $p_i = (x, y)$ če $D = 2$ ali vksel $p_i = (x, y, z)$ če $D = 3$
- **Binarna slika** je osnovi množica (delno-) povezanih pikslov
 - ▣ Na primer piksli, ki so označeni z 1 predstavljajo množico $I = \{p_i\}$

Teoretično ozadje

- **Binarna regija** je lahko:

- Prazna množica $R = \emptyset$
- Posameznik (ang. singleton) $R = \{p\}$
- Množica povezanih pikslov $R = \{p_i\}$

- **Povezanost** določa množica vseh podmnožic:

- Zagotavlja delno urejenost glede na vključenost!
- V praksi uporabljamo 4 ali 8 povezanost

- **Povezana komponenta** je množica povezanih pikslov

Teoretično ozadje

- Koliko povezanih komponent ima spodnja slika?


[illegible]

Teoretično ozadje

- Dve vrst matematične morfologije:
 - ▣ Pristop, ki temelji na pikslih
 - ▣ Pristop, ki temelji na povezanih komponentah

- **Strukturni element** definira okolico zanimanja opazovanega piksla:
 - ▣ Množica premikov pikslov p_i
$$S_{p_i} = \{p_i + t_j\} ,$$
kjer je t_j vektor premika

 - ▣ Z drugimi besedami, S definira kako premaknemo piksele dane binarne slike
 - Običajno kvadrat ali krog



Osnovne definicije

□ Širjenje (ang. dilation)

- $\delta(I)[p_i] = \cup_{p_j \in S_{p_i}} \{S_{p_j}\}$




- Unija vseh premikov slike

□ Krčenje (ang. erosion)

- $\varepsilon(I)[p_i] = \cap_{p_j \in S_{p_i}} \{S_{p_j}\}$

- Presek vseh premikov slike

Strukturni element




Osnovne definicije – Sivinska morfologija


- **Diskretna funkcija preslikave** $f: P \rightarrow \mathbb{R}$ predstavlja sliko, kjer vsaki vrednosti iz P (torej p_i) priredi realno število
 - ▣ npr. nadmorsko višino, intenziteto, ...
- **Širjenje (ang. dilation)**
 - ▣ $\delta(f)[p_i] = \bigvee_{p_j \in S_{p_i}} f(p_j)$
- **Krčenje (ang. erosion)**
 - ▣ $\varepsilon(f)[p_i] = \bigwedge_{p_j \in S_{p_i}} f(p_j)$

- $\bigvee = \textit{infimum}$
 - Najmanjši element, ki je večji ali enak podanim vrednostim
- $\bigwedge = \textit{supremum}$
 - Največji element, ki je manjši ali enak podanim vrednostim


Osnovne definicije – Sivinska morfologija




(a)



(b)



(c)



(d)

ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS

Vsebina

- Odpiranje in zapiranje
- Cilindrična transformacija
- Geodetske operacije in povezani operatorji
- Dekompozicija in „MaxTree“



Odpiranje in zapiranje

□ Notacije

- ▣ f - slika
- ▣ $S = \{s_j\}$ - strukturni element
- ▣ p_i - piksel

□ Širjenje in krčenje

- ▣ $\delta(f)[p_i] = \vee_S f[p_i + s_j]$
- ▣ $\varepsilon(f)[p_i] = \wedge_S f[p_i + s_j]$

□ Odpiranje in zapiranje

- ▣ $\gamma(f) = \delta(\varepsilon(f))$
- ▣ $\phi(f) = \varepsilon(\delta(f))$

Vhod:



Odpiranje



Zapiranje



Odpiranje in zapiranje

Vhod:



Odpiranje in zapiranje

Odpiranje:



Odpiranje in zapiranje



Zapiranje:



Cilindrične transformacije

□ Bela: $f - \gamma(f)$

□ Črna: $\phi(f) - f$



Morfološka rekonstrukcija

□ Elementarno geodetsko širjenje in krčenje:

- $\delta_m^1(f) = \min(\delta^1(f), m)$
- $\varepsilon_m^1(f) = \max(\varepsilon^1(f), m)$
- kjer je m maska

□ Geodetsko širjenje:

- $\delta_m^s(f) = \delta_m^1 \left(\delta_m^1 \left(\delta_m^1 \left(\dots \delta_m^1(f) \right) \right) \right),$
- kjer s definira število iteracij.

Morfološka rekonstrukcija

□ Geodetska rekonstrukcija

- $\delta_m(f) = \lim_s (\delta_m^s(f))$


- $\varepsilon_m(f) = \lim_s (\varepsilon_m^s(f))$

□ Odpiranje in zapiranje z rekonstrukcijo


- $\gamma_m^s(f) = \delta_m(\varepsilon^s(f))$

- $\phi_m^s(f) = \varepsilon_m(\delta^s(f))$


Vhodna slika




Krčenje




Širjenje (odpiranje)




Rekonstrukcija




Rekonstrukcija






Rekonstrukcija




Rekonstrukcija



Rekonstrukcija



...



Rezultati




Rezultati

Odpiranje pri $S = 3$



Bela cilindrična transformacija




Rezultati

Zapiranje pri $S = 3$



Črna cilindrična transformacija



Povezani operatorji

- Operatorji imajo naslednje lastnosti:
 - ▣ Naraščajoč: $f \leq g \Rightarrow \psi(f) \leq \psi(g)$
 - ▣ Idempotenten: $\forall f, \psi(\psi(f)) = \psi(f)$
 - ▣ Raširjajoč: $\forall f, f \leq \psi(f)$
 - ▣ Skrčujoč: $\forall f, \psi(f) \leq f.$

- Morfološki filter je naraščajoč in idempotenten operator
 - ▣ Odpiranje je skrčujoče, zapiranja pa razširjajoče

- Povezan operator deluje nad ravninskimi regijami
 - ▣ nikoli ne „prelomi“ ravninske regije


Strukturna in tekstura dekompozicija

- Struktura slike predstavlja grobe oblike objektov
- Tekstura predstavlja lokalne variacije v intenzitetah

Vhodna slika




Gauss



Rekonstrukcija





Razlika



Atributni filtri

- Omogočajo filtriranje glede na poljubne attribute, na primer površino, širino, obliko, ...
- Temeljijo na superpoziciji pragovnih vrednosti



- Učinkovita implementacija v enem prehodu (MaxTree)

Atributni filtri

- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



Atributni filtri

- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



A = 2000

Atributni filtri


- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



$$A = 10000$$

Atributni filtri

- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



Razlika med $A = 2000$ in $A = 10000$

Atributni filtri

- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



Atributni filtri

- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



A = 100

Atributni filtri


- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



A = 150

Atributni filtri

- Odpiranje glede na površino:
 - ▣ Ekvivalentno maksimumu odpiranj z vsemi možnimi enakovelikimi povezanimi strukturnimi elementi



Razlika med $A = 100$ in $A = 150$

ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS

Vsebina

- Diferencialni morfološki profili
- Teksturna analiza
 - ▣ Histogrami (hitra ponovitve)
 - ▣ Sivinska matrika sopojavitev

Diferencialni profil


- Profiliranje z zaporednimi cilindričnimi transformacijami:
 - ▣ Odstranjene strukture, ki sovpadajo s filtri




-



=





Morfološka dekompozicija




Morfološka dekompozicija



□ Diferencialni morfološki profili:



Morfološka dekompozicija




Morfološka dekompozicija



Mapiranje karakterističnih vrednosti


Vhod




Največji odzivi



Velikost okna





Deviacija odzivov



Hribi in doline


- Po enakem principu izdelamo profile za zapiranje



- Primerjamo profile:
 - ▣ Če je večji dobljen z odpiranjem je hrib, sicer dolina

Analiza teksture

- Osnovni pristopi:
 - ▣ Histogrami
 - ▣ Sivinska sopojavitvena matrika
- Histogram $H[k] = \text{število elementov v košu } k$
 - ▣ $K = \text{število košev}$
 - ▣ $k \in [0, K-1]$



Analiza teksture - Histogram

□ Kako določiti število košev K?

- $K = \frac{Max\ n - Min\ n}{h}$, kjer je h velikost koša

- $K = \sqrt{n}$

- Normalna porazdelitev običajno

$$k = \lceil \log_2 n \rceil + 1,$$

- Izboljšava za nenormalno porazdelitev

$$k = 1 + \log_2(n) + \log_2 \left(1 + \frac{|g_1|}{\sigma_{g_1}} \right)$$

Analiza teksture - Histogram

- Povprečje na osnovi histograma

$$\bar{n} = \frac{\sum_{k=0}^K k * H[k]}{\sum_{k=0}^K H[k]}$$

- Pričakovana vrednost = $\arg \max H[k]$

- Kako izračunamo mediano?

- Standardni odklon

$$\bar{n} = \sqrt{\frac{\sum_{k=0}^K k * (H[k] - \bar{n})}{\sum_{k=0}^K H[k]}}$$

Analiza tekstone - Histogram

□ Spremenljivost

$$m_1 = \frac{\sum (x_i - \bar{x})}{N}$$


$$m_2 = \frac{\sum (x_i - \bar{x})^2}{N}$$

$$m_3 = \frac{\sum (x_i - \bar{x})^3}{N}$$

$$m_4 = \frac{\sum (x_i - \bar{x})^4}{N}$$

Asimetrija (skewness)

$$b_1 = \frac{m_3}{s^3} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left[\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \right]^{3/2}},$$



Analiza tekstone - Histogram

□ Spremenljivost

$$m_1 = \frac{\sum (x_i - \bar{x})}{N}$$


$$m_2 = \frac{\sum (x_i - \bar{x})^2}{N}$$

$$m_3 = \frac{\sum (x_i - \bar{x})^3}{N}$$

$$m_4 = \frac{\sum (x_i - \bar{x})^4}{N}$$


Sploščenost (kurtosis)

$$g_2 = \frac{m_4}{m_2^2} - 3 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{\left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2\right)^2} - 3$$




Matrika sopojavitve sivinskih vrednosti

- Ang. gray level cooccurrence matrix
 - ▣ GLCM
- Porazidelitev parov vrednosti na določenem odmiku
- GLMC podaja frekvenco pojavitve piksla z vrednostjo i na podanem odmiku (horizontalno, vertikalno ali diagonalno) od vrednosti j
 - ▣ Notacija odmikov: $P_{0,D}$, $P_{D,0}$, $P_{D,D}$, $P_{-D,D}$




Matrika sopojavitve sivinskih vrednosti

- GLCM je v bistvu histogram sopojavitvenih vrednosti



Matrika sopojavitve sivinskih vrednosti

- GLCM je v bistvu histogram sopojavitvenih vrednosti



Statistike nad GLCM

- Homogenost

$$H(P) = \sum_{i=0}^{255} \sum_{j=0}^{255} \frac{GLCM(i, j)}{1 + (i - j)^2}$$

- Kontrast

$$C(P) = \sum_{i=0}^{255} \sum_{j=0}^{255} GLCM(i, j)(i - j)^2$$

- Entropija



$$E(P) = \sum_{i=0}^{255} \sum_{j=0}^{255} -GLCM(i, j) \log_e(GLCM(i, j))$$

Primer uporabe

- PANTEX v uporabi EC za detekcijo naselij (predvsem begunskih kampov in nelegalnih naselji)



- Definicija

- ▣ $\text{Min}(C(P))$, kjer $P =$



Primer uporabe

□ Jeruzalem:



ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS


Vsebina

- Definicija segmentacije
- Algoritem razvodja
 - ▣ Princip vodne kapljice
 - ▣ Simulacija poplav
 - ▣ Nadzor z označevalci
- Ostale metode (povezane z razvodjem)




Segmentacija

- **Segmentacija** je proces vzpostavitve particije
 - ▣ Particija je delitev množice v množico nepraznih podmnožic tako, da je vsak element vključen v natanko eno množico.
- Segmentacija omogoča **objektni pristop** k razpoznavi objektov:
 - ▣ Velikost, tekstura, ...
- **Natančnost segmentacije:**
 - ▣ Idealno 1 segment = 1 objekt
 - ▣ Objekt ni nujno tudi razpoznan!



Segmentacija razvodja

- Dva pristopa:
 - ▣ Simulacija padca kapljice
 - ▣ Simulacija poplav




Princip vodne kapljice

- Vodna kapljica steče v smer največje strmine
 - ▣ Morfološko krčenje
- Algoritem:
 - ▣ Obišči vsak piksel
 - ▣ Poišči najnižjega v sosesčini
 - ▣ Določi pot
 - ▣ V drugem prehodu obarvaj regije

16.8	19.2	13.5	20.5	31.2	30.1
18.7	11.9	15.4	18.5	22.1	18.4
20.1	21.9	26.6	20.8	17.3	18.1
25.3	22.8	20.9	19.8	15.1	15.9
30.7	35.5	29.9	18.7	17.6	39.9
34.8	38.6	33.4	32.7	33.5	36.7


Princip vodne kapljice

- Vodna kapljica steče v smer največje strmine
 - ▣ Morfološko krčenje
- Algoritem:
 - ▣ Obišči vsak piksel
 - ▣ Poišči najnižjega v sosesčini
 - ▣ Določi pot
 - ▣ V drugem prehodu obarvaj regije





Princip vodne kapljice

- Ravninske regije
 - ▣ Povzročajo matematično nestabilnost
- Rešitev
 - ▣ Sekundarne uteži glede na transformacijo razdalje
- Običajna izvedba nad sliko zaznanih robov ali transformacijo razdalje





Princip vodne kapljice

- Algoritem:
 - ▣ Zaznava robov
 - ▣ Odstranjevanje majhnih o robov
 - ▣ Segmentacija z razvodjem




Princip vodne kapljice

- Algoritem:
 - ▣ Zaznava robov
 - ▣ Odstranjevanje majhnih o robov
 - ▣ Segmentacija z razvodjem



PRIMER: Ločevanje povezanih objektov

- Algoritem:
 - ▣ Pragovno filtriranje
 - ▣ Transformacija razdalje in invert slike
 - ▣ Segmentacija z razvodjem




Princip simulacije poplave

- Voda postopno zaliva površje
 - ▣ Intenziteto interpretiramo kot višino površja
- Algoritem:
 - ▣ Indeksiraj lokalne minimume in jih vstavi v prioriteto vrsto
 - ▣ Odstrani najnižje
 - ▣ Indeksiraj sosede in jih vstavi v prioriteto vrsto

16.8	19.2	13.5	20.5	31.2	30.1
18.7	11.9	15.4	18.5	22.1	18.4
20.1	21.9	26.6	20.8	17.3	18.1
25.3	22.8	20.9	19.8	15.1	15.9
30.7	35.5	29.9	18.7	17.6	39.9
34.8	38.6	33.4	32.7	33.5	36.7

Princip simulacije poplave

- Voda postopno zaliva površje
 - Intenziteto interpretiramo kot višino površja
- Algoritem:
 - Indeksiraj lokalne minimume in jih vstavi v prioriteto vrsto
 - Odstrani najnižje
 - Indeksiraj sosede in jih vstavi v prioriteto vrsto



Nadzor z označevalci

□ Algoritem:

- ▣ Indeksiraj semena in jih dodaj v prioriteto vrsto
- ▣ Odstrani najnižjega
- ▣ Indeksiraj sosede in jih vstavi v prioriteto vrsto

16.8	19.2	13.5	20.5	31.2	30.1
18.7	11.9	15.4	18.5	22.1	18.4
20.1	21.9	26.6	20.8	17.3	18.1
25.3	22.8	20.9	19.8	15.1	15.9
30.7	35.5	29.9	18.7	17.6	39.9
34.8	38.6	33.4	32.7	33.5	36.7

Nadzor z označevalci

- Ang. marker-controlled watershed



Nadzor z označevalci

- Ang. marker-controlled watershed




ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA

DOMEN MONGUS

Vsebina

- Ang. Shape Descriptors
- Vrednost, ki okarakterizira obliko:
 - ▣ Neodvisno od velikosti
 - ▣ Neodvisno od rotacije
 - ▣ Neodvisno od položaja



Želene lastnosti

- Definira urejenost glede na podobnost:
 - ▣ Podobne oblike imajo podobne vrednosti
 - ▣ Različne oblike imajo različne vrednosti
 - ▣ Male razlike v obliki pomenijo male razlike v vrednosti atributa
- Pristopi:
 - ▣ Glede na površino
 - ▣ Glede na mejo
 - ▣ Večkomponentni



PRIMER: Razpoznava simetričnih oblik


□ Želene lastnosti:

□ Zaloga vrednosti $[0,1]$:

- 1 pomeni „simetričen“
- 0 pomeni „popolnoma nesimetričen“

□ Možnosti:

- Konveksnost
- Linearnost
- Kombinacije?



Atributi, ki izhajajo iz površine

- Najbolj popularni in zelo robustni:
 - ▣ Odporni na šum, ozke meje, itd.
 - ▣ Posledično primerni za delo s podatki slabe kvalitete

- Primeri:
 - ▣ Statistični momenti
 - ▣ Orientacija oblike
 - ▣ Podolgovatost
 - ▣ Okroglost (vključuje poznavanje meje)

Statistični momenti površine

□ (p,q)-ti moment je določen z $m_{p,q}(S) = \iint_S x^p y^q dx dy$.

■ v diskretnem svetu je to: $\sum i^p \cdot j^q$

■ Centroid: $(x_c(S), y_c(S)) = \left(\frac{m_{1,0}(S)}{m_{0,0}(S)}, \frac{m_{0,1}(S)}{m_{0,0}(S)} \right)$

□ (p,q)-ti centralni moment je določen z

$$\overline{m}_{p,q}(S) = \iint_S (x - x_c(S))^p (y - y_c(S))^q dx dy$$

□ Neodvisnost od velikosti $\mu_{p,q}(S) = \frac{\overline{m}_{p,q}(S)}{m_{0,0}(S)^{1 + \frac{p+q}{2}}}$

Statistični momenti površine

□ Neodvisnost od velikosti $\mu_{p,q}(S) = \frac{\overline{m}_{p,q}(S)}{m_{0,0}(S)^{1+\frac{p+q}{2}}}$

□ Neodvisnost od rotacije (Hujevi momenti):

$$I_1 = \mu_{2,0} + \mu_{0,2}$$

$$I_2 = (\mu_{2,0} - \mu_{0,2})^2 + 4 \cdot (\mu_{1,1})^2$$

$$I_3 = (\mu_{3,0} - 3 \cdot \mu_{1,2})^2 + (3 \cdot \mu_{2,1} - \mu_{0,3})^2$$

$$I_4 = (\mu_{3,0} + \mu_{1,2})^2 + (\mu_{2,1} + \mu_{0,3})^2$$

$$I_5 = (\mu_{3,0} - 3 \cdot \mu_{1,2}) \cdot (\mu_{3,0} + \mu_{1,2}) \cdot [(\mu_{3,0} + \mu_{1,2})^2 - 3 \cdot (\mu_{2,1} + \mu_{0,3})^2] \\ + (3 \cdot \mu_{2,1} - \mu_{0,3}) \cdot (\mu_{2,1} + \mu_{0,3}) \cdot [3 \cdot (\mu_{3,0} + \mu_{1,2})^2 - (\mu_{2,1} + \mu_{0,3})^2]$$

$$I_6 = (\mu_{2,0} - \mu_{0,2}) \cdot [(\mu_{3,0} + \mu_{1,2})^2 - (\mu_{2,1} + \mu_{0,3})^2] \\ + 4 \cdot \mu_{1,1} \cdot (\mu_{3,0} + \mu_{1,2}) \cdot (\mu_{2,1} + \mu_{0,3})$$

$$I_7 = (3 \cdot \mu_{2,1} - \mu_{0,3}) \cdot (\mu_{3,0} + \mu_{1,2}) \cdot [(\mu_{3,0} + \mu_{1,2})^2 - 3 \cdot (\mu_{2,1} + \mu_{0,3})^2] \\ + (\mu_{3,0} - 3 \cdot \mu_{1,2}) \cdot (\mu_{2,1} + \mu_{0,3}) \cdot [3 \cdot (\mu_{3,0} + \mu_{1,2})^2 - (\mu_{2,1} + \mu_{0,3})^2].$$

Orientacija oblike

- Premica, definirana z minimizacijo vsote kvadratov razlik (podobno linearni regresiji).
- Kot premice podan kot
$$\frac{\sin(2\alpha)}{\cos(2\alpha)} = \frac{2 \cdot \overline{m}_{1,1}(S)}{\overline{m}_{2,0}(S) - \overline{m}_{0,2}(S)}$$
- Očitna težava $\overline{m}_{2,0}(S) - \overline{m}_{0,2}(S) = 0$
 - Kako koristno uporabiti zgornjo enačbo?

Podolgovatost

- Razlika med primarno in sekundarno osjo

$$\frac{\overline{m}_{2,0}(S) + \overline{m}_{0,2}(S) + \sqrt{4 \cdot (\overline{m}_{1,1}(S))^2 + (\overline{m}_{2,0}(S) - \overline{m}_{0,2}(S))^2}}{\overline{m}_{2,0}(S) + \overline{m}_{0,2}(S) - \sqrt{4 \cdot (\overline{m}_{1,1}(S))^2 + (\overline{m}_{2,0}(S) - \overline{m}_{0,2}(S))^2}}$$

- Zaloga vrednosti?

- ▣ $[1, \infty)$

- Vse rotacijsko simetrične oblike imajo vrednost 1

Okroglost

- Lastnosti:
 - ▣ Zaloga vrednosti: $(0,1]$
 - ▣ $1 = \text{krog}$
 - ▣ $0 = \text{neskončno dolga črta}$
 - ▣ Neodvisnost od rotacije, translacije ali položaja
 - ▣ Majhne spremembe oblike vodijo v majhne spremembe vrednosti!

- Izračun:
$$\frac{4 * \pi * \text{Površina}}{\text{Obseg}^2}$$

Primeri



Okroglost
Podolgovatost

(a):0.9579
(0.4881)

(b):0.8755
(0.4937)

(c):0.6765
(0.3508)

(d):0.4506
(0.2733)

(e):0.4385
(0.2679)



Okroglost
Podolgovatost

(f):0.3810
(0.1981)

(g):0.3361
(0.2148)

(h):0.2776
(0.2082)

(i):0.1390
(0.1545)

(j):0.0729
(0.0982)

Primeri

□ Odpornost na šum



a):0.7470
(0.3155)



b):0.7520
(0.3039)



c):0.7565
(0.2289)



d):0.7412
(0.1367)

Okroglost
Podolgovatost

Atributi, ki izhajajo iz meje

- Manj popularni zaradi:
 - ▣ Nižja stopnja robustnosti
 - ▣ Zahtevnejša implementacija

- Prednosti
 - ▣ Večja natančnost
 - ▣ Lahko obravnavajo linearne objekte (na primer podpise)

- Primeri:
 - ▣ FFT
 - ▣ Ukrivljenost
 - ▣ Konveksnost

FFT

- Meja predstavljena kot množica točk (x_i, y_i)
- Izračunamo center (x_c, y_c)
- Definiramo tabelo:
$$\begin{pmatrix} x_0 - x_c & y_0 - y_c \\ \vdots & \vdots \\ x_I - x_c & y_I - y_c \end{pmatrix}$$
- Izračunamo FFT zgornje tabele
 - ▣ Rezultat določa „valovitost“ meje

Ukrivljenost

- Meja predstavljena kot množica točk (x_i, y_i)
- Izračunamo odvode:
 - ▣ $\dot{x}, \dot{y}, \ddot{x}$ in $\ddot{y}$,
- Mapa ukrivljenosti
 - ▣ $k_i = \frac{\dot{x}_i \ddot{y}_i - \dot{y}_i \ddot{x}_i}{(\dot{x}_i^2 + \dot{y}_i^2)^{3/2}}$
- Gauss za glajenje

Običajni atributi:

- Točke prehoda čez 0
- Dolžine intervalov
- Število pozitivnih in negativnih intervalov

....

Konveksnost

- DEFINICIJA: Krivulja je konveksna, če daljica med dvema poljubnima točka na krivulji ne seka krivulje.
 - ▣ Verjetnost, da bo daljica med naključno izbranimi točkama na krivulji (lahko je tudi nepovezana) sekala krivuljo?
- Lastnosti:
 - ▣ Zaloge vrednosti: $(0,1]$
 - ▣ 1 = konveksno, 0 ni mogoče doseči
 - ▣ Neodvisnost od rotacije, translacije ali položaja
 - ▣ Majhne spremembe oblike vodijo v majhne spremembe vrednosti!


Konveksnost




(a)



(b) $M = 0.309$



(c) $M = 0.767$



(d) $M = 0.708$

□ Visoka časovna zahtevnost

- Zunic J, Rosin PL. Convexity measure for shapes with partially extracted boundaries. Electronics Letters. 2007 Mar 29;43(7):380-2.

PRIMER: Konveksnost

8 8 4 4 3 2 5 5 9 3

0.512 0.528 0.538 0.581 0.590 0.611 0.625 0.648 0.677 0.678

6 9 2 6 0 1 1 7 0 7

0.681 0.694 0.762 0.775 0.841 0.877 0.887 0.936 0.947 1.000

Henri Matisse

0.067

Henri Matisse

0.083

Henri Matisse

0.097

Henri Matisse

0.113

H Matisse

0.169

H. Matisse

0.183

Dr. Seuss

0.225

Dr. Seuss

0.247

Dr Seuss


0.256

ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA


DOMEN MONGUS

Tradicionalni pristop OPDZ

- Spoznali smo kar nekaj tehnik za to




Tradicionalne tehnike strojnega učenja



Tehnike globokega učenja (naslavlajo drugi predmeti)

- Združujejo oba koraka...



Semantično označevanje satelitskih slik

- PRIMER: Dejanska raba prostora
 - ▣ RAZREDI: Zazidano, njiva, travnik, gozd, vodna, ...
 - ▣ APLIKACIJE: črne gradnje, degradira območja, zaraščanje travnikov, kontrola kmetijskih subvencij,...

- Ključen izziv:
 - ▣ Spektralno prekrivanje vzorcev

Spektralno prekrivanje


- RAZLOG: Spekter odboja odvisen od vpadne svetlobe in spektralnih karakteristik materiala
- PRIMER: voda in sence ... zakaj?
- Nobene garancije, da je sta voda in sence edini problem




Tradicionalni pristop

- Razpoznavna senc in izvedba radiometričnih korekcij
 - ▣ NPR. izvedba DMR, projekcija senc in popravki slike
- OPOMBA: Skoraj nepomembno kateri klasifikator uporabite
 - ▣ Teoretično najboljši naivni Bayes

Napake [pas 8]




Pravilne razpoznave [pas 8]




Obnašanje klasifikatorjev (Sentinel 2 pas 8)

- Spektralno prekrivanje:
 - ▣ Ne območjih prekrivanja značilk razpoznavna ni mogoče,
 - ▣ Izven območja prekrivanja je razpoznavna dobra

Odstotek napak



Odstotek pravih razpoznav



Ansambelske metode

- OSNOVNA IDEJA: Več glav več ve!
 - ▣ Učenje več klasifikatorjev
 - ▣ „Demokratsko“ glasovanje vsakega klasifikatorja
- Najbolj poznani primeri so:
 - ▣ Naključni gozd
 - ▣ (Ada)boost
 - ▣ **Bayesovo povprečenje:**
 - OSNOVNA IDEJA: Uporaba Bayesove logike za seštevanje glasov posameznih klasifikatorjev
 - KORAKI:
 - ▣ Učenje klasifikatorjev
 - ▣ Statistično vrednotenje vsakega
 - ▣ Izdelava Bayesovega klasifikatorja nad rezultati

Naključni gozd

- IDEJA: Naključno generiranje več naključnih dreves
 - ▣ Vsako drevo ima 1 glas
- Zasnovan kot „bootstrap“ algoritem:
 - ▣ Naključno vzorčenje učne množice tako, da:
 - Množica ostane enako velika
 - Vsak element vhodne učne množice se lahko pojavi 0-krat, 1-krat ali n-krat v učni množici posameznega drevesa
 - Vsaka množica ustvari svojo drevo

(Ada)boost

- IDEJA: Inkrementalno učenje ansambla tako, da je vsak nov model bolje prilagojen na napake prejšnjega
 - ▣ Še vedno ima vsak klasifikator 1 glas
- Koraki:
 - ▣ Naključna izvedba prvega modela
 - ▣ Preverjanje modela
 - Večjo verjetnost izbora vzorca damo nepravilno razpoznanim vzorcem
 - ▣ Učenje novega modela



Konstrukcija klasifikacijskih orkestroev za razpoznavo dejanske rabe tal

□ Definicija pragovne vrednosti in razpoznavo z dvema klasifikatorjema

▣ Kako definiramo pragovno vrednost?

Klasifikator #1

Klasifikator #2





Konstrukcija klasifikacijskih orkestroev za razpoznavo dejanske rabe tal

□ Definicija pragovne vrednosti in razpoznavo z dvema klasifikatorjema

- ▣ Kako definiramo pragovno vrednost?
 - Meritev informacijskega prirastka
 - Izgradnja odločitvenega drevesa


Klasifikator #1

Klasifikator #2




Konstrukcija klasifikacijskih orkestro

- Informacijski prirastek:
 - ▣ entropija množice – utežena vsota entropij podmnožic
- (Linearna) struktura orkestra:



Klasifikacijski rezultati


- Teoretično nad učno množico vedno dosežemo 100% natančnost.
- ▣ Kaj pa nad testno?




Klasifikacijski rezultati

- Kaj je optimalno število iteracij:
 - ▣ V našem primeru se rast ustvati po 8-10 iteracij
 - ▣ Dosežemo „overfitting“

Učna množica



Testna množica



Rezultati

■ Built-Up ■ Farmland ■ Forest ■ Meadow ■ Water

