

KLASIČNO: dolžina vektorja: $\|a\| = \sqrt{\sum_{i=1}^n a_i^2}$ skalarni produkt: $a \cdot b = \sum_{i=1}^n a_i b_i$ povprečje: $\mu = \frac{\sum_{i=1}^N x_i}{N}$

Standardni odklon: $\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$ varianca: $\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$

AKTIVACIJSKE FUNKCIJE:

ReLU: $f(s) = \max(0, s) \rightarrow$ odreže info **Leaky ReLU:** $f(s) = \max(as, s) \rightarrow a > 0$ **MaxOut:** $f(x) = \max(w_0 x + b_0, w_1 x + b_1)$

Sigmoidna: $f(s) = \frac{1}{1+e^{-s}} \rightarrow s = 0 \rightarrow 0.5 \quad s = \infty \rightarrow \approx 1 \quad s = -\infty \approx 0$ izhodna plast!

UČENJE NM: PREHOD NAPREJ: izguba: $L_i = L(x_i, y_i, t(x_i), w)$ $L_i \dots$ izguba za i-ti vhod, **strošek:** $J(w) = E(\sum_i L_i)$.

PREHOD NAZAJ: popravljamo uteži $\rightarrow$ Nove uteži = stare uteži + $g(\nabla J) \rightarrow$ stroškovna funkcija.

STROŠKOVNE FUNKCIJE: $MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ **MAE** $= \frac{\sum_{i=1}^n |y_i - x_i|}{n}$ **Cross-entropy:** $-\sum_{i=1}^K t_i * \log_2 p_i$

K razredov; t_i – verjetnost, da vhod pripada i-temu razredu

$BCE_{loss} = -[t * \log_2(p) + (1 - t) * \log_2(1 - p)]$ **Softmax:** $s(z_1) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$ z ... izhod iz nevronske mreže

Dim. Izhodne slike CNN: (FxF) - Velikost filtra, P - Padding, S - Korak $\rightarrow M_2 = \frac{M_1 - F + 2P}{S + 1}$ **Dim. izhodne s. Pooling:** $M_2 = \frac{M_1 - F}{S + 1}$

HIPERSPEKTRALNO ZAJEMANJE: Spektralni kot $= \theta = \arccos \frac{\vec{x} \cdot \vec{t}_i}{|\vec{x}| * |\vec{t}_i|}$ Kosinusna razdalja $= \cos \theta = \frac{\vec{x} \cdot \vec{t}_i}{|\vec{x}| * |\vec{t}_i|}$

x ... spekter piksla, t ... ciljni spekter

PEGASTI ŠUM: Aditivni šum: $I(p) = X(p) + N(p)$ Multiplikativni šum: $I(p) = X(p) * N(p)$

I - šumna slika; X - brezšumna slika; N - šum; p = [i, j]; σ = standardni odklon; μ = povprečje v določenem oknu

MERJENJE VPLIVA ŠUMA: $MSE = \frac{1}{MN} \sum_i \sum_j (I(p) - \hat{X}(p))^2$ **RMSE** $= \sqrt{MSE}$ **PSNR** $= 20 \log_{10} \left(\frac{\max(I(p))}{RMSE} \right) [dB]$

$SNR = 10 \log_{10} \frac{\sigma_I^2}{\sigma_X^2} [dB]$ $SNR = \frac{\mu_I}{\sigma_I}$ $S/MSE = 10 \log_{10} \frac{\sum_i \sum_j \hat{x}(p)^2}{\sum_i \sum_j (I(p) - \hat{X}(p))^2} [dB]$

Ocenjevanje nivoja peg. šuma v SAR: $ENL = \left(\frac{\mu_I}{\sigma_I} \right)^2 = \frac{1}{\sigma_N} = L$ ($\sigma_N \dots$ varianca šuma; šum ima avg. $\mu_N = 1$)

Adaptivni mediana filter – Definiramo večjo masko H_1 (znotraj mešičkov) in manjšo masko H_2 (na robovih) $\rightarrow$ Vse piksele manjše od praga T filtriramo z masko H_1 , preostale z $H_2 \rightarrow$ Korak 2 lahko izvedemo 2x.

Kuanov filter – multiplikativni šum: $I(p) = X(p) + (N(P) - 1) * X(p)$; šum ima povprečje 1

Postopek: $\hat{X}(p) = \mu_I + \frac{\sigma_X^2(I(p) - \mu_I)}{\sigma_X^2 + (\mu_I + \sigma_X^2)/L}$ $\sigma_X^2 = \frac{L\sigma_I^2 - \mu_I^2}{L+1}$ $\hat{X}(p)$ = kako filtriramo piksel p; Če je $\sigma_X^2 < 0 \rightarrow \hat{X}(p) = \mu_I$

Leejev (MMSE) filter: $\hat{X}(p) = \mu_I + \frac{\sigma_X^2(I(p) - \mu_I)}{\mu_I + \sigma_X^2}$

Filter GAMA: $\hat{X}(p) = \frac{(\alpha - L - 1)\mu_I + \sqrt{\mu_I(\alpha - L - 1)^2 + 4 * \alpha * L * \mu_I * I(p)}}{2\alpha}$ $\alpha = \frac{L+1}{L\left(\frac{\sigma_I}{\mu_I}\right)^2}$ $\alpha \dots$ od okna do okna za vsak premik

Frostov filter: $h = e^{-K * C_I * (t_0) * \|t\|}$ $C_I = \frac{\sigma_I}{\mu_I}$ (K – parameter filtra (ponavadi 1), C_I – fiksno za eno okno, t_0 – lokacija piksla, ki ga računamo, $\|t\|$ – razdalja merjena od t_0 oz. od središčnega piksla maske (center je 0). Vsak piksel svoja maska; $\|t\|_{3 \times 3} = [[\text{sqrt}(2), 1, \text{sqrt}(2)], [1, 0, 1], [\text{sqrt}(2), 1, \text{sqrt}(2)]]$

Oddyjev filter (3x3): če je $m < \alpha \mu_I \rightarrow \hat{X}(p) = \mu_I$, drugače $\frac{\sum_k \sum_l \sum_{kl} I(k, l)}{\sum_k \sum_l W_{kl}}$ $m = \frac{1}{8} \sum_k \sum_l |I(k, l) - I(p)|$

Če je $|I(k, l) - I(p)| \leq m \rightarrow W_{kl} = 1$, drugače $W_{kl} = 0$

1. Imamo podan pixel z okolico 2. Izračunamo abs(okoliški piksel – centralni), sešteješ te vrednosti in pomnožiš z 1/8 (to je zdaj m) 3. pogledamo tiste abs vrednosti in primerjamo če so $> ali < m$ 4. upoštevaš pogoje in polniš matriko W

Filter AFS: Vrednost l.e.s (ploščina) izračunaš za 9 binarnih mask znotraj okna velikosti 5x5 (samo sešteješ pixle v okolici) $\rightarrow$ Izbereš masko z minimalno vrednostjo l.e.s (izmed teh 9 mask) $\rightarrow$ Filtriraš z nizkim sitom izbrano masko $\rightarrow$ Dobljeno vrednost prirediš središčnemu pikslu okna, velikosti 5x5

BARVNA VZTRAJNOST

Model za formiranje barvnih vrednosti piksla: $C_v(p) = \int_{\lambda} S_v(\lambda) E(\lambda, p) d\lambda$ (λ -valovna dolžina, p - piksel, v -barvni kanal)

Poenostavitev zgornje enačbe: $C_v(p) = G(p)R_v(p)L_v(p)$ (R-odbojnost predmetov, L-spekter svetlobe, G-geom. faktor)

Algoritem WPR: $L = \max(C(p))$, nato: $O(p) = G(p)R(p) = \frac{C(p)}{L}$

Algoritem GWA: $O(p) = \frac{C(p)}{C_{\varphi}}$ ($\overline{C}$ - povp. vrednost barvnega kanala, φ - faktor povečave (npr. 2))

Algoritem CCN - iteriramo: 1. $O'(p) = \frac{C(p)}{C_R(p)+C_G(p)+C_B(p)}$, 2. $O(p) = \frac{O'(p)}{C_{\varphi}}$ 3. $C(p) = O(p)$

Algoritem LSAC: $O(p) = \frac{C(p)}{L(p)} = \frac{C(p)}{\overline{C}(p)\varphi}$, $\overline{C}(p) = C(p) * K(p)$, $K(p) = K(x, y) = a^{-1}e^{-\frac{x^2+y^2}{2p^2}}$, $p = 0.093 \max(M, N)$ (K-jedro, MxN slika)

Algoritem RSR: P množic, vsaka vsebuje K pikslov. $p_{p,k} = [i_{p,k}, j_{p,k}]$ -k-ti piksel p-te množice.

$i_{p,k} = i + r\eta \cos(\mu)$, $j_{p,k} = i + r\eta \sin(\mu)$, $n \in U(0, 1)$, $\mu \in U(0, 2\pi)$, $p = [i, j]$, r -radij razpršene množice.

$O(p) = \frac{1}{P} \sum_{p=1}^P \frac{C(p)}{\max_k(C(p_{p,k}))}$

KONTURE – KAČE: Položaj kače $v(s) = [x(s), y(s)]$ s ... dolžina krožnega loka $s \in [0, 1]$

E_{int} ... Notranje sile zlepk zaradi upogibanja E_{image} ... slikovne sile (matrika enake dimenzije kot slika)

E_{con} ... sile zunanjih omejitev C_{yy} ... 2. parcialni odvod C_x ... 1. parcialni odvod **EF** ... energijski funkcional

EF kače: $E_{snake} = \int_0^1 (E_{int}(v(s)) - E_{image}(v(s)) + E_{con}(v(s))) ds$ $\int$... seštevek vseh sil

Interna energija: $E_{int} = \frac{1}{2} (\alpha(s) * |v_s(s)|^2 + \beta(s) * |v_{ss}(s)|^2) \rightarrow E_{int}$ računamo za eno vozlišče (s); α je utež (kako se bo kača obnašala kot membrana); β je utež (kako se bo kača obnašala kot pleh); v_s je 1. odvod naše krivulje s po krožnem loku; v_{ss} je 2. odvod (še enkrat odvajaš 1. odvod) Če je $\beta(s) = 0 \rightarrow$ vogali

Slikovne sile: $E_{image} = w_{line} * E_{line} + w_{edge} * E_{edge} + e_{term} * E_{term}$ w ... uteži

Linijski funkcional: $E_{line} = I(x, y)$ **Funkcional zaključkov:** $E_{term} = \frac{C_{yy}C_x^2 - 2C_{xy}C_xC_y + C_{xx}C_y^2}{(C_x^2 + C_y^2)^{\frac{3}{2}}}$

Robni funkcional: $E_{edge} = -|\nabla I(x, y)|^2 \rightarrow$ minimiziramo (večji gradient $\rightarrow$ močno potegne vrednost dol)

Jakost gradienta za nek piksel: $|\nabla(p)| = \sqrt{\left(\frac{\partial I}{\partial x}(p)\right)^2 + \left(\frac{\partial I}{\partial y}(p)\right)^2}$

Minimizacija EF kače: energijo kače diskretiziramo $E_{snake} = \sum_{i=1}^n E_{int}(i) + E_{ext}(i)$ i -to vozlišče: $v_i = [x_i, y_i]$, kjer sta x začetek in y konec. $\rightarrow E_{int}(i) = \alpha_i \frac{|v_i - v_{i-1}|^2}{2h^2} + \beta_i \frac{|v_{i-1} - 2v_i + v_{i+1}|^2}{2h^4}$ h ... korak

$v_s(i) = \frac{\overrightarrow{v_i - v_{i-1}}}{h}$... Če bi 2. odvod računal pa jemlješ te $\overrightarrow{v_s}$, ki jih dobiš z 1. odvodom $\rightarrow$ dolžina: $|\overrightarrow{v_s}|^2 = x_i^2 + y_i^2$

Naj bo $\mathcal{F}_x(i) = \frac{\partial E_{ext}}{\partial x_i}$ in $\mathcal{F}_y(i) = \frac{\partial E_{ext}}{\partial y_i}$. Dobimo **Eulerjevo enačbo** za i -to vozlišče: $\alpha_i(v_i - v_{i-1}) + \alpha_{i+1}(v_{i+1} - v_i) + \beta_{i-1}(v_{i-2} - 2v_{i-1} + v_i) - 2\beta_i(v_{i-1} - 2v_i + v_{i+1}) + \beta_{i+1}(v_i - 2v_{i+1} + v_{i+2}) + (\mathcal{F}_x(i), \mathcal{F}_y(i)) = 0$.

To zapišemo v matrični enačbi kot: $Ax + F_x(x, y) = 0$ in $Ay + F_y(x, y) = 0 \rightarrow Ax$ - v stolpec zložimo št. vrstic Ay - v stolpec zložimo št. stolpcev F_x - stolpec, kjer za vsako vozlišče odčitamo parcialni odvod za naša vozlišča

To enačbo rešimo kot: $x_t = (A + \gamma I)^{-1}(\gamma x_{t-1} - F_x(x_{t-1}, y_{t-1}))$ in $y_t = (A + \gamma I)^{-1}(\gamma y_{t-1} - F_y(x_{t-1}, y_{t-1}))$

γI ... identiteta γx_{t-1} in γy_{t-1} ... stare koordinate

Pentadiagonalna matrika A		Algoritem kac
$\begin{bmatrix} cba0000\dots 0ab \\ bcba000\dots 00a \\ abcba00\dots 000 \\ 0abcba0\dots 000 \\ \dots\dots\dots \\ 000000\dots abcba \\ 000000\dots 0abc b \\ 000000\dots 00abc \end{bmatrix}$	$a = \beta$ $b = -(\alpha + 4/\beta)$ $c = 2\alpha + 6\beta$ zgornje velja, ce $\alpha_i = \alpha$ in $\beta_i = \beta$	1. Vnesi zacetni priblizek (krivuljo) iskanega objekta. 2. Enakomerno razporedi n vozlišč po krivulji. 3. Določi E_{ext} po enacbi (13). 4. Izračunaj $F_x = \frac{\partial E_{ext}}{\partial x}$ in $F_y = \frac{\partial E_{ext}}{\partial y}$ 5. Doloci matriko A 6. WHILE (ni izpolnjen konvergeneni pogoj) Doloci nov polozaj vozlic kace v iteraciji t po enacbi (16). $t = t + 1$ Enakomerno razporedi n vozlic po krivulji.

Približki parcialnih odvodov: $I =$

X1	X2	X3
X4	X5	X6

$\frac{\partial I}{\partial x}(x5) = x5 - x2$ $\frac{\partial I}{\partial y}(x5) = x5 - x4$

X smer je navpična, y pa vodoravna