

4. Napredna segmentacija

Posplošena Houghova transformacija

Modeli aktivnih kontur – kače

Analiza neodvisnih komponent

Posplošena Houghova transformacija

- ▷ Pomembne informacije o objektu v sliki so pogostokrat skrite v obliki njegove meje (*boundary*):
 - ★ notranja in zunanja meja objekta (glej zapiske predavanj URVRV, poglavje 4)
- ▷ Houghova transformacija (HT) je metoda za detektiranje krivulj, pri čemer izkorišča dualnost med točkami krivulje in parametri te iste krivulje.
- ▷ Obstaja HT za detektiranje:
 - ★ analitičnih krivulj in
 - ★ neanalitičnih krivulj
- ▷ HT se opira na informacijo o:
 - ★ **robni piksli**
 - ▷ uporaba zgolj informacije o jakosti robnega piksla oz. gradienta
 - ★ **celotni sliki robov**
 - ▷ rob je vektorska spremenljivka; rob = [jakost roba, smer gradienta]
 - ▷ uporabljata se obe informaciji
- ▷ Pojmi: slika robov (*edge image*), robni piksel (*edge pixel*), jakost gradienta, smer gradienta (glej zapiske predavanj URVRV, poglavje 3).

A. HT za analitične krivulje

- ▷ Mejo iskanega objekta lahko predstavimo z analitično krivuljo.
- ▷ Splošno analitično krivuljo zapišemo v obliki:

kjer $\mathcal{F}(\mathbf{x}, \mathbf{a}) = 0$

- ★ $\mathbf{x}$ – slikovna točka oz. piksel
- ★ $\mathbf{a}$ – vektor parametrov krivulje

1. HT za iskanje linij oz. premic


- ▷ Povzetek, podrobnosti v zapiskih predavanj URVRV, poglavje 4

- ▷ Klasična enačba premice:

$$y = kx + n$$

- ▷ Normalna oz. parametrična oblika enačbe:

$$x \cos \theta + y \sin \theta = r$$



- ▷ HT preslika točke iz kartezijske 2D-ravnine (tj. x, y) v parametrični prostor modela (tj. r, θ)

- ★ primer: točke premice p se preslikajo v isto točko v Houghovem prostoru

Posplošena Houghova transformacija

(3)

- ▷ HT apliciramo na binarni sliki (npr. binarizirani sliki robov)
- ▷ Za piksele v sliki pa seveda ne vemo, kakšna(e) premica(e) poteka(jo) skozi njih (če sploh!):
 - ★ skozi posamezen piksel lahko torej teoretično potekajo premice z vsemi možnimi smermi θ
- ▷ Piksel $\mathbf{p} = [i, j]$ se s HT preslika v sinusno krivuljo:
 - ★ Pri znani orientaciji, tj. θ , izračunamo oddaljenost r kot:

$$r = i \cos \theta + j \sin \theta \quad (2)$$

- ★ izračun naredimo pri vseh možnih orientacijah, rezultat pa shranimo v akumulatorsko polje $A(\theta, r)$
 - ▷ Houghov parametrični prostor in izračunane vrednosti moramo diskretizirati!

Postopek:

1. Inicializiraj akumulator A , tj. $A(\theta, r) = 0$
2. FOR vsak robni piksel
 - FOR $\theta = \min_{\theta} : \Delta\theta : \max_{\theta}$
 - Izračunaj enačbo (2)
 - $A(\theta, r) = A(\theta, r) + \Delta A$
3. Poišči lokalne maksimume v akumulatorju A , kar ustreza položajem premic v sliki.


2. HT za iskanje krožnic, izključno na osnovi robnih pikslov

- ▷ Klasična enačba krožnice:

$$(x - a)^2 + (y - b)^2 = r^2$$

- ▷ Postavimo si naslednje vprašanje:

- ★ Če naj bi piksel $p = [x, y]$ ležal na krožnici, kaj je možen prostor parametrov (a, b, r) za to krožnico (v parametričnem prostoru)?



Odgovor: Pravilni krožni stožec (vir: [1]).

- ▷ Če v sliki dejansko obstaja krožnica, potem se bo množica takšnih pravilnih krožnih stožcev sekala v skupni točki.
- ▷ Potrebujemo 3D akumulator A , tj. $A(a, b, r)$.

Posplošena Houghova transformacija

(5)

Postopek:

1. Inicializiraj akumulator A, tj. $A(a, b, r) = 0$
2. FOR vsak robni piksel
 FOR $a = \min_a : \Delta a : \max_a$
 FOR $b = \min_b : \Delta b : \max_b$
 $r = \sqrt{(x - a)^2 + (y - b)^2}$
 $A(a, b, r) = A(a, b, r) + \Delta A$
3. Poišči lokalne maksimume v akumulatorju A, kar ustreza položajem krožnic v sliki.

DN:

- ▷ HT za iskanje elips, izključno na osnovi robnih pikslov

$$\frac{(x - x_0)^2}{a^2} + \frac{(y - y_0)^2}{b^2} = 1$$

- ▷ HT za iskanje elips, izključno na osnovi robnih pikslov, pri čemer je glavna os elipse rotirana za kot φ glede na os x

$$\begin{aligned}x(t) &= x_0 + a \cos t \cos \varphi - b \sin t \sin \varphi \\y(t) &= y_0 + a \cos t \sin \varphi + b \sin t \cos \varphi\end{aligned}$$

3. HT za analitične krivulje v sivinskih slikah, na osnovi vseh informacij iz slike robov

- ▷ Iz originalne slike moramo izračunati kompletno sliko robov:
 - ★ jakost oz. velikost gradienta (na tej osnovi določamo robne piksele!)
 - ★ smer gradienta ψ
- ▷ V HT uporabljamo tako originalno enačbo krivulje

$$\mathcal{F}(\mathbf{x}, \mathbf{a}) = 0 \quad (3)$$

kakor tudi njen odvod

$$\frac{d\mathcal{F}}{dx}(\mathbf{x}, \mathbf{a}) = 0 \quad (4)$$

- ▷ V odvodu dobimo člen $\frac{dy}{dx}$, ki je poznan, saj

$$\frac{dy}{dx} = \operatorname{tg}\left[\psi(\mathbf{x}) - \frac{\pi}{2}\right]$$


Postopek:

1. Inicializiraj akumulator A , tj. $A(\mathbf{a}) = 0$
2. FOR vsak robni piksel
 - Izračunaj vse parametre $\mathbf{a}$, za katere veljata enačbi (3) in (4)
 - $A(\mathbf{a}) = A(\mathbf{a}) + \Delta A$
3. Poišči lokalne maksimume v akumulatorju A .

Posplošena Houghova transformacija

(7)

- ▷ Če v HT uporabljamo še informacijo o smeri gradienta, se računska zahtevnost bistveno zmanjša.
- ▷ **Primer:**
 - ★ Pri iskanju krožnic s tem postopkom, se število prostih parametrov zmanjša na 1.
 - ★ Prostor možnih parametrov se iz stožca zreducira na premico.



Prostor možnih parametrov pri iskanju krožnic s pomočjo informacije o smeri gradienta.

4. HT za iskanje elips v sivinskih slikah, s pomočjo informacije o smeri gradienta

▷ Začetna predpostavka:

- ★ elipsa orientirana tako, da je njena glavna os vzporedna z x -osjo (v nadaljevanju bomo dodali še rotacijo!)

▷ Enačba elipse:

$$\frac{(x - x_0)^2}{a^2} + \frac{(y - y_0)^2}{b^2} = 1 \quad (5)$$

▷ Vpeljimo $X = x - x_0$ in $Y = y - y_0$ ter odvajamo po X . Dobimo

$$\frac{2X}{a^2} + \frac{2Y}{b^2} \frac{dY}{dX} = 0 \quad (6)$$

▷ Vrednost $\frac{dY}{dX}$ je poznana iz informacije o robnem pikslu:

- ★ označimo:

$$\frac{dY}{dX} = \xi$$

▷ Iz enačb (5) in (6) izračunamo

$$Y = \pm \frac{b^2}{\sqrt{1 + \frac{a^2}{b^2} \xi^2}} \quad X = \pm \frac{a^2}{\sqrt{1 + \frac{b^2}{a^2} \xi^2}} \quad (7)$$

Posplošena Houghova transformacija

(9)

- ▷ Torej: Če poznamo a, b, x, y in $\frac{dY}{dX}$ potem določimo x_0 in y_0 kot

$$y_0 = y \pm \frac{b^2}{\sqrt{1 + \frac{a^2}{b^2} \xi^2}} \quad x_0 = x \pm \frac{a^2}{\sqrt{1 + \frac{b^2}{a^2} \xi^2}} \quad (8)$$

- ★ Dobimo štiri rešitve v štirih kvadrantih.
- ★ Pravilen kvadrant izberemo na osnovi testiranja predznaka izrazov dY in dX

- ▷ Upoštevajmo še rotacijo elipse, tj. parameter φ

- ★ Parameter ξ se sedaj določi kot

$$\xi = \operatorname{tg}(\psi - \varphi - \frac{\pi}{2}) \quad (9)$$

- ★ Z izračunanim ξ določimo X in Y
- ★ Na koncu dobljeno točko (X, Y) rotiramo za kot φ , s čimer dobimo središče elipse (x_0, y_0)

Posplošena Houghova transformacija

(10)

Postopek:

1. Inicializiraj akumulator A , tj. $A(x_0, y_0, \varphi, a, b) = 0$
2. FOR vsak robni piksel
 - FOR $a = \min_a : \Delta a : \max_a$
 - FOR $b = \min_b : \Delta b : \max_b$
 - FOR $\varphi = \min_\varphi : \Delta\varphi : \max_\varphi$
 - Izračunaj enačbo (9).
 - Določi X in Y po enačbi (7), pri čemer določi predznak na osnovi opazovanja dY in dX .
 - Rotiraj X in Y za kot φ .
 - $x_0 = x + X$
 - $y_0 = y + Y$
 - $A(x_0, y_0, \varphi, a, b) = A(x_0, y_0, \varphi, a, b) + \Delta A$
3. Poišči lokalne maksimume v akumulatorju A , kar ustreza položajem elips v sliki.

B. Posplošitev HT za neanalitične krivulje

- ▷ Za opis oblike neanalitične krivulje uporabljamo naslednji vektor parametrov


$$\mathbf{a} = [\mathbf{y}, \mathbf{s}, \varphi]$$

kjer

- ★ $\mathbf{y} = [x_0, y_0]$ – referenčno izhodišče za obliko (krivuljo)
 - ★ φ – orientacija krivulje
 - ★ $\mathbf{s} = [s_x, s_y]$ – ortogonalna skalirna faktorja (v praksi $s_x = s_y$)
 - ★ Položaj referenčnega izhodišča $\mathbf{y}$ opišemo v obliki tabele možnih orientacij robnih pikslov (tj. R-tabela)
- ▷ Ključna stvar pri posplošitvi HT je uporaba informacije o smeri gradienta:
 - ★ ne le, da pohitri algoritem, ampak tudi bistveno izboljša natančnost!

1. R-tabela

- ▷ R-tabelo skonstruiramo v učni fazi za vsako iskano obliko.



Postopek:

1. Izberi referenčno točko y znotraj iskane oblike.
2. FOR vsako točko x iz meje
Izračunaj smer gradienta $\psi(x)$.
 $r = y - x$
Shrani r v R-tabelo v odvisnosti od $\psi(x)$.

Primer: Oblika R-tabele [1]

i	ψ_i	R_{ψ_i}
0	0	$\{r y - r = x \wedge \psi(x) = 0 \wedge x \text{ je na meji}\}$
1	$\Delta\psi$	$\{r y - r = x \wedge \psi(x) = \Delta\psi \wedge x \text{ je na meji}\}$
2	$2\Delta\psi$	$\{r y - r = x \wedge \psi(x) = 2\Delta\psi \wedge x \text{ je na meji}\}$
...	...	...

Lastnosti R-tabele

Za iskano obliko poznamo njeno R-tabelo, tj. $R(\psi)$:

▷ Kakšna je nova R-tabela, $R'(\psi)$, pri znani transformaciji?

1. Skaliranje oblike (objekta) za faktor s

$$R'(\psi) = sR(\psi) \quad (10)$$

2. Rotiranje oblike (objekta) za kot φ

$$R'(\psi) = \text{Rotacija}\{R[(\psi - \varphi) \bmod 2\pi], \varphi\} \quad (11)$$

- ▷ vse indekse najprej inkrementiramo za $(-\varphi \bmod 2\pi)$
- ▷ dobljene vektorje $\mathbf{r}$ pa rotiramo za kot φ

3. Sprememba referenčne točke iz $\mathbf{y}$ v $\mathbf{y}'$

$$R'(\psi) = R(\psi) + (\mathbf{y} - \mathbf{y}')$$

2. Iskanje poljubnih oblik

1. Inicializiraj akumulator A , tj. $A(\mathbf{y}, s, \varphi) = 0$
2. FOR vsak robni piksel $\mathbf{x}$
 FOR $s = \min_s : \Delta s : \max_s$
 FOR $\varphi = \min_\varphi : \Delta\varphi : \max_\varphi$
 Določi R' po enačbi (10).
 Vstavi R' v enačbo (11) in določi R'' .

 FOR $\mathbf{r} \in R''(\psi(\mathbf{x}))$
 $A(\mathbf{x} + \mathbf{r}, s, \varphi) = A(\mathbf{x} + \mathbf{r}, s, \varphi) + \Delta A$
3. Poišči lokalne maksimume v akumulatorju A .

▷ Učinkovite implementacije posplošene HT in njene variante najdemo v [2].

C. Inkrementalne strategije in kompenziranje napak

1. Inkrementalne strategije

- ▷ Če v vsaki iteraciji inkrementiramo akumulator za 1, potem je vsebina akumulatorja proporcionalna obsegu iskane oblike:
 - ★ takšna strategija preferira iskanje oblik, kjer je velik del objekta (krivulje) možno detektirati
- ▷ Če želimo detektirati krajše, zelo pomembne dele objekta (npr. v primeru delnega zakrivanja objektov), potem so primernejše alternativne inkrementalne strategije:

$$A(\mathbf{a}) = A(\mathbf{a}) + |\text{grad}(\mathbf{x})|$$

ali pa kombinacija obojega


$$A(\mathbf{a}) = A(\mathbf{a}) + |\text{grad}(\mathbf{x})| + \text{konstanta}$$

2. Detektiranje lokalnih maksimumov

- ▷ Pri detektiranju maksimumov v akumulatorju A se lahko pojavijo problemi:
 - ★ mnogi faktorji vplivajo na natančnost izračunanega vektorja $\mathbf{a}$
 - ▷ **Posledica: Ob idealni točki $\mathbf{a}$ inkrementiramo v akumulatorju še množico lokacij v neposredni okolici te točke!**
- ▷ Pokazalo se je [1], da z glajenjem akumulatorja odpravimo nenatančnosti pri izračunu smeri gradienta in vektorja $\mathbf{r}$.

Analiza neodvisnih komponent

- ▷ Analiza neodvisnih komponent (*independent component analysis – ICA*) je splošno namenska metoda obdelave signalov in analize podatkov:
 - ★ v osnovi je bila razvita za reševanje problemov, ki so sorodni **problemu zabave s koktajli**
- ▷ **Zabava s koktajli (*cocktail-party problem*):**
 - ★ Problem: V sobi imamo več govorcev in več mikrofонов.
 - ★ Cilj: Izluščiti glas individualnega govorca od preostalih glasov, na osnovi vseh signalov, posnetih z mikrofoni.



Vir: [6]

- ▷ Metoda ICA izvaja linearno projekcijo na neodvisne komponente.

A. Matematična formulacija metode

- ▷ Opazujemo n linearnih mešanic, $x_1(t), x_2(t), \dots, x_n(t)$, ki sestojijo iz n neodvisnih komponent $s_i(t)$:

$$x_j(t) = a_{j1}s_1(t) + a_{j2}s_2(t) + \dots + a_{jn}s_n(t) \quad \forall j$$

- ▷ V nadaljevanju indeks t izpustimo ter predpostavimo, da je vsaka mešanica x_j in vsaka neodvisna komponenta s_k naključna spremenljivka
 - ★ $x_j(t)$ – opazovana vrednost, npr. signal na mikrofону, v problemu zabave s koktajli, je vzorec te naključne spremenljivke
- ▷ Predpostavka: spremenljivke mešanice, kakor tudi neodvisne komponente imajo ničelno povprečje (*zero mean*)
 - ★ Če to ne drži, lahko od opazovanih spremenljivk vedno odštejemo povprečje vseh vzorcev, s čimer ga centriramo in naredimo model z ničelnim povprečjem.

Analiza neodvisnih komponent

(3)

- ▷ Mešalni model (*mixing model*) zapišemo v matrični notaciji:

$$\underbrace{\mathbf{X}}_{n \times N} = \underbrace{\mathbf{A}}_{n \times n} \underbrace{\mathbf{S}}_{n \times N} \quad (17)$$

kjer

- ★ n – število opazovanih spremenljivk in neodvisnih komponent
- ★ N – število vzorcev (v spremenljivki)
- ★ $\mathbf{A}$ – mešalna matrika
- ★ teorijo je možno razviti tudi v primeru, kadar se števili opazovanih spremenljivk, n , in število neodvisnih komponent, p , razlikujeta (tipično: $n > p$)

- ▷ Model, podan z enačbo (17), se imenuje analiza neodvisnih komponent oz. model ICA.
- ▷ Model ICA je generativen model: opisuje, kako se opazovani podatki generirajo v procesu mešanja neodvisnih komponent s_i .
- ★ neodvisne komponente so latentne oz. prikrite spremenljivke (*latent variables*), ki jih ni možno direktno opazovati.
 - ★ mešalna matrika $\mathbf{A}$ ni znana.

Analiza neodvisnih komponent

(4)

- ▷ Rešujemo naslednji problem:
 - ★ na osnovi opazovanja linearnih mešanic X , ocenjujemo tako mešalno matriko A , kot neodvisne komponente S
- ▷ Brez vpeljave določenih predpostavk ta problem ni rešljiv!
- ▷ Običajno sprejmemo naslednje predpostavke:
 1. komponente s_i so statistično neodvisne
 2. neodvisne komponente ne smejo imeti Gaussovo porazdelitev
 3. neznana mešalna matrika je kvadratna (to omejitev je možno tudi omiliti)
- ▷ Po ocenitvi matrike A najprej izračunamo njen inverz W , neodvisne komponente pa določimo kot

$$S = WX \quad (18)$$

- ▷ Metoda ICA je tesno povezana z **metodo slepega ločevanja izvorov oz. signalov (*blind source separation* – BSS)**:
 - ★ "izvor" – originalen signal oz. neodvisna komponenta
 - ★ "slepo" – vemo zelo malo (lahko tudi nič) o mešalni matriki in naredimo majhne predpostavke o izvornih signalih
 - ★ Je najbolj pogosto uporabljena metoda za izvajanje slepega ločevanja izvorov.

B. Nejasnosti oz. nedoločljivosti v metodi ICA

1. Ne moremo določiti variance (energije) neodvisnih komponent.
 - ▷ V praksi: Neodvisne komponente so naključne spremenljivke, za katere predpostavimo, da imajo varianco enako 1.
 - ★ Ta omejitev se nato upošteva pri adaptiranju matrike A.
 - ▷ Kljub zgornji predpostavki ostane še nejasnost predznaka v rešitvi:
 - ★ neodvisne komponente lahko pomnožimo z -1, ne da bi vplivali na model
2. Ne moremo določiti točnega vrstnega reda neodvisnih komponent:
 - ▷ vsako od neodvisnih komponent lahko obravnavamo kot prvo!

Ocenjevanje neodvisnosti oz. princip ocenitve ICA

- ▷ Ključ k ocenjevanju modela ICA je "ne Gaussov" (*nongaussianity*).
 - ★ Vemo: brez predpostavke o ne Gaussovi porazdelitvi ocenjevanje niti ni možno.

Mere za merjenje "ne Gaussov"

- ▷ Naj bo naključna spremenljivka y z ničelnim povprečjem ter varianco enako 1.

1. Kurtozis

$$kurt(y) = E\{y^4\} - 3(E\{y^2\})^2 \stackrel{\text{pred.}}{=} E\{y^4\} - 3$$

- ▷ Za Gaussove naključne spremenljivke je kurtozis enak 0, za večino ostalih pa je različen od 0.
 - ★ Kurtozis ni dovolj robustna mera – zelo občutljiva na osamelce (*outliers*).

2. Negentropija

- ▷ Negentropija (*negentropy*) temelji na informacijsko-teoretični vrednosti (diferencialne) entropije.
- ▷ Entropijo naključne spremenljivke interpretiramo kot stopnjo informacije, ki jo daje opazovanje spremenljivke.
 - ★ Bolj "naključna", tj. nepredvidljiva in nestrukturirana je spremenljivka, večja je entropija.
 - ★ Rezultat informacijske teorije [7]: Gaussova spremenljivka ima največjo entropijo med vsemi naključnimi spremenljivkami z isto varianco.
- ▷ Negentropija je vedno ne negativna in je 0 tedaj in le tedaj, ko ima y Gaussovo porazdelitev.

Analiza neodvisnih komponent

(7)

- ▷ Določiti negentropijo je računsko izredno zahtevno, zato v praksi raje uporabljamo njene približke.
- ▷ Primer približka negentropije, $J(y)$ [7]:

$$J(y) = [E\{\mathcal{G}(y)\} - E\{\mathcal{G}(v)\}]^2$$

kjer

- ★ $\mathcal{G}$ – poljubna nekvadratična funkcija
- ★ v – Gaussova spremenljivka z ničelnim povprečjem in varianco enako 1

- ▷ Zelo primerni sta se izkazali naslednji funkciji $\mathcal{G}$:

$$\mathcal{G}(u) = \frac{1}{a} \log \cosh au$$

$$\mathcal{G}(u) = -e^{-\frac{u^2}{2}}$$

kjer

- ★ a – konstanta iz intervala $[1, 2]$

C. Predobdelava za metodo ICA

- ▷ Cilj predobdelave: Narediti problem ocenitve ICA preprostejši in boljše pogojen.

1. Centriranje

- ▷ Centriramo opazovane vrednosti v X :
 - ★ odštejemo povprečni vektor, tj. $\mathbf{m} = E\{X\}$
 - ★ dejansko od vsake vrstice matrike X odštejemo povprečno vrednost
 - ▷ po centriranju X vsebuje spremenljivke z ničelnim povprečjem
 - ▷ tudi originali v S postanejo spremenljivke z ničelnim povprečjem
- ▷ Po ocenitvi mešalne matrike A s centriranimi podatki, prištejemo k centriranim ocenam v S še povprečen vektor $A^{-1}\mathbf{m}$.

2. Beljenje (*whitening*)

- ▷ Centrirane opazovane vektorje nato še linearno transformiramo tako, da postanejo "beli":
 - ★ tj. njihove komponente so nekorelirane, njihova varianca pa je 1.
 - ★ Kovariančna matrika transformiranih podatkov je enaka identiteti:
 - ▷ kovariančno matriko določimo tako, da izračunamo kovarianco med vsakim parom signalov oz. vrstic matrike X (Matlab: $cov(X', 1)$).

Analiza neodvisnih komponent

(9)

- ▷ Beljenje izvedemo z dekompozicijo na lastne vrednosti kovariančne matrike netransformiranih podatkov:

$$E\{\mathbf{x}\mathbf{x}^T\} = \mathbf{E}\mathbf{D}\mathbf{E}^T$$

kjer

- ★ $\mathbf{E}$ – ortogonalna matrika lastnih vektorjev
- ★ $\mathbf{D}$ – diagonalna matrika pripadajočih lastnih vrednosti

- ▷ Beljenje opravimo z množenjem opazovanih vektorjev $\mathbf{X}$ s faktorjem $\mathbf{D}^{-\frac{1}{2}}\mathbf{E}^T$, tj.

$$\tilde{\mathbf{X}} = \mathbf{D}^{-\frac{1}{2}}\mathbf{E}^T\mathbf{X}$$

- ▷ Po analizi ICA pa opravimo še t.i. razbeljenje (*dewhitening*) dobljene mešalne matrike s faktorjem $\mathbf{E}\mathbf{D}^{\frac{1}{2}}$, tj.

$$\mathbf{A} = \mathbf{E}\mathbf{D}^{\frac{1}{2}}\tilde{\mathbf{A}}$$

D. Algoritem ICA

1. Postopek za en stolpec inverzne mešalne matrike $\mathbf{W}$

1. Naključno določi stolpec $\mathbf{w}$ (dimenzije $n \times 1$).
2. Izračunaj

$$\mathbf{w}^+ = E\{\mathbf{X}\mathcal{G}'(\mathbf{X}^T \mathbf{w})\} - E\{\mathcal{G}''(\mathbf{X}^T \mathbf{w})\}\mathbf{w}$$

3. $\mathbf{w} = \mathbf{w}^+ / \|\mathbf{w}^+\|$
4. IF $\left((\mathbf{w}^T \mathbf{w} - 1) < \epsilon\right)$ Konec; ELSE Korak 2

Opombe:

- ▷ Podatki morajo biti centrirani in razbeljeni!
- ▷ $\mathcal{G}'$ in $\mathcal{G}''$ sta prvi in drugi odvod funkcije $\mathcal{G}$, s katero ocenjujemo negentropijo.
- ▷ ϵ – majhno pozitivno število
- ▷ $E\{\mathbf{X}\mathcal{G}'(\mathbf{X}^T \mathbf{w})\}$ izračunamo:
 - ★ najprej določimo $\mathbf{X}\mathcal{G}'(\mathbf{X}^T \mathbf{w})$, s čimer dobimo stolpec dimenzije $n \times 1$
 - ★ vsak element stolpca zatem delimo s številom vzorcev (tj. z N)

2. Postopek za celotno inverzno mešalne matrike $\tilde{W}$

1. FOR vsak stolpec matrike $\tilde{W}$

Izvedi postopek za en stolpec (točka 1).

2. Dekoreliraj vrstice v matriki $\tilde{W}$, npr. kot

$$\tilde{W} = \tilde{W} / \sqrt{\|\tilde{W}\tilde{W}^T\|}$$

REPEAT

$$\tilde{W} = \frac{3}{2}\tilde{W} - \frac{1}{2}\tilde{W}\tilde{W}^T\tilde{W}$$

UNTIL rezultat ne konvergira

3. Določi originalno mešalno matriko A z razbeljenjem:


$$A = ED^{\frac{1}{2}}\tilde{W}^{-1}$$

Opombe:




- ▷ Matrika $\tilde{W}$, ki jo določimo z zgornjim postopkom je inverzna mešalna matrika za predobdelane podatke!

E. Aplikacije metode ICA



1. Problem zabave s koktajli



$$A = \begin{bmatrix} 0,3 & 0,7 \\ 0,5 & 0,5 \end{bmatrix}$$



⇓ ICA



2. Ločevanje mešanice slik




$$A = \begin{bmatrix} 0,35 & 0,65 \\ 0,6 & 0,4 \end{bmatrix}$$




⇓ ICA



prikaz: skaliranje na
interval $[0, 255]$



3. Odstranjevanje šuma



Vir: [6, 7]

▷ Ideja:

1. Na brezšumni množici podatkov določi transformacijo W .
2. Ocenimo množico parametrov.
3. Izvedi transformacijo W na šumnih podatkih.
4. Nad dobljenim rezultatom apliciraj operator krčenja (*shrinkage operator*).
5. Rezultat na koncu transformiraj s W^T v prostor originalnih spremenljivk.

▷ Različice metode ICA za odstranjevanje šuma so opisane v [8].

4. Določanje značilnic: Primer razpoznavanja obrazov [9]



Originali.

⇓ ICA



Baza neodvisnih slik.

$$\text{Original Face} = b_1 \text{IC}_1 + b_2 \text{IC}_2 + \dots + b_n \text{IC}_n$$

- ▷ Vektor značilnic $\mathbf{b} = [b_1, b_2, \dots, b_n]$ – uporabimo za razpoznavanje

Dodatna literatura

- [1] D.H. Ballard (1981), Generalizing the Hough transform to detect arbitrary shapes, Pattern recognition, vol. 13, str. 111–122.
- [2] A.A. Kassim, T. Tan, K.H. Tan (1999), A comparative study of efficient generalised Hough transform techniques, Image and vision computing, vol. 17, str. 737–748.
- [3] M. Kass, A. Witkin, D. Terzopoulos (1987), Snakes: Active contour models, International journal of computer vision, vol. 1, št. 4, str. 321–331.
- [4] N.P. Tiilikainen, A comparative study of active contour snakes, <ftp://ftp.diku.dk/diku/image/publications/nikolas.070901.pdf>
- [5] A. Klemenčič, S. Kovačič, A. Leonardis (1995), Redundant initialization and selection of active contour models for image segmentation, V: Zborniku 19 konference OAGM, Maribor, Slovenija, str. 240–248.
- [6] M. Journee (2008), Matlab project: Independent component analysis, http://www.inma.ucl.ac.be/absil/Grenoble2008/Grenoble_Matlab_project.pdf
- [7] A. Hyvarinen, E. Oja (2000), Independent Component Analysis: Algorithms and applications, Neural networks, vol. 13, št. 4–5, str. 411–430.
- [8] P. Anjali, S. Ajay, S.D. Sapre (2010), A review on natural image denoising using independent component analysis (ica) technique, Advances in computational research, vol. 2, št. 1, str. 6–14.
- [9] A. Rajgarhia (2007), Face detection using independent component analysis, <http://cs229.stanford.edu/proj2007/Rajgarhia-FaceDetectionUsingICA.pdf>

5. Slikovne transformacije

2D Fourierova transformacija

2D Valčna transformacija

2D Fourierova transformacija

A. Ponovitev: 1D signali

- ▷ Fourierova ugotovitev:
 - ★ vsak signal je možno predstaviti kot vsoto sinusov, ki imajo različne amplitude, frekvence in fazne zamike
 - ★ dejansko gre za zapis signala v novem vektorskem prostoru, kjer so bazni vektorji sinusi
- ▷ Fourierova transformacija (FT) transformira signal iz časovnega prostora v frekvenčni prostor!
 - ★ Časovna predstavitev (prostor):
 - ▷ neodvisna spremenljivka t (čas)
 - ▷ $x = x(t)$
 - ★ Frekvenčna predstavitev (prostor):
 - ▷ neodvisna spremenljivka ω (krožna frekvenca; $\omega = 2\pi f$)
 - ▷ $X = X(\omega)$
 - ▷ vsak signal je popolnoma opredeljen z naborom trojic (A, f, φ)

2D Fourierova transformacija

(2)

1D zvezna FT

- ▷ Transformacijski par:

$$\mathbb{X}(\omega) = \int_{-\infty}^{+\infty} x(t) e^{-i\omega t} dt$$

$$x(t) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \mathbb{X}(\omega) e^{i\omega t} d\omega$$

kjer

★ $i = \sqrt{-1}$ – imaginarna enota

★ $e^{-i\omega t} = \cos(\omega t) - i \sin(\omega t)$

- ▷ **Oznaka za Fourierovo transformacijo: $\mathcal{F}[\]$ oz. $\mathcal{F}^{-1}[\]$.**

1D diskretna FT

- ▷ Transformacijski par:

$$\mathbb{X}(k) = \sum_{n=0}^{N-1} x(n) e^{-i \frac{2\pi}{N} kn}, \quad k = 0, 1, \dots, N-1$$

$$x(n) = \frac{1}{N} \sum_{k=0}^{N-1} \mathbb{X}(k) e^{i \frac{2\pi}{N} kn}, \quad n = 0, 1, \dots, N-1$$

2D Fourierova transformacija

(3)

B. 2D Zvezna FT

- ▷ Gre za posplošitev FT za 2D signale (tj. slike).
- ▷ Zvezna slika $\mathcal{I}$ je funkcija dveh neodvisnih spremenljivk (slikovnih koordinat):

$$\mathcal{I} = \mathcal{I}(x, y)$$

- ▷ FT opravi dekompozicijo slikovne funkcije s pomočjo linearne kombinacije na ortonormalne funkcije (t.i. harmonične funkcije).
- ▷ Transformacijski par:

$$\mathcal{F}[\mathcal{I}(x, y)] = \mathbb{I}(u, v) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \mathcal{I}(x, y) e^{-i2\pi(xu+yv)} dx dy$$

$$\mathcal{F}^{-1}[\mathbb{I}(u, v)] = \mathcal{I}(x, y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \mathbb{I}(u, v) e^{i2\pi(xu+yv)} du dv$$

kjer

- ★ u in v – prostorski frekvenci (*spatial frequency*)
- ★ $e^{i2\pi(xu+yv)}$ – preprost periodični vzorec

2D Fourierova transformacija

(4)

C. 2D Diskretna FT

▷ Transformacijski par:

$$\mathbb{I}(k_1, k_2) = \frac{1}{MN} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} l(m, n) e^{-i2\pi(\frac{mk_1}{M} + \frac{nk_2}{N})} \quad (19)$$

$$k_1 = 0, 1, \dots, M - 1$$

$$k_2 = 0, 1, \dots, N - 1$$

$$l(m, n) = \sum_{k_1=0}^{M-1} \sum_{k_2=0}^{N-1} \mathbb{I}(k_1, k_2) e^{i2\pi(\frac{mk_1}{M} + \frac{nk_2}{N})}$$

$$m = 0, 1, \dots, M - 1$$

$$n = 0, 1, \dots, N - 1$$

2D Fourierova transformacija

(5)

Možna implementacija 2D FT

▷ Enačbo (19) zapišimo kot

$$\mathbb{I}(k_1, k_2) = \frac{1}{M} \sum_{m=0}^{M-1} \left(\frac{1}{N} \sum_{n=0}^{N-1} I(m, n) e^{-\frac{i2\pi nk_2}{N}} \right) e^{-\frac{i2\pi mk_1}{M}}$$

$$k_1 = 0, 1, \dots, M - 1$$

$$k_2 = 0, 1, \dots, N - 1$$

▷ **Opazimo:**

- ★ izraz v oklepaju ustreza 1D FT m -te vrstice
- ★ ta izračun lahko opravimo s hitro Fourierovo transformacijo – FFT (ob predpostavki, da je $N = 2^v$)
- ★ vsako vrstico zamenjamo z njeno Fourierovo transformiranko
- ★ zatem pa opravimo še 1D DFT nad vsakim stolpcem

D. Interpretacija 2D DFT

- ▷ Fourierova transformacija realne funkcije (kar slikovna funkcija vsekakor je!) je kompleksna funkcija:

$$\mathbb{I}(k_1, k_2) = Re(k_1, k_2) + iIm(k_1, k_2)$$

kjer

★ $Re(k_1, k_2)$ – realni del in $Im(k_1, k_2)$ – imaginarni del

- ▷ Na področju obdelave slik ima interpretacija slikovnega Fourierovega spektra zelo pomembno vlogo.
- ▷ **Frekvenčni spekter (*frequency spectrum*)**
 - ★ za enak pomen najdemo še izraze: **amplitudni spekter, funkcija velikosti**

$$|\mathbb{I}(k_1, k_2)| = \sqrt{Re^2(k_1, k_2) + Im^2(k_1, k_2)}$$

- ▷ **Fazni spekter (*phase spectrum*)**

$$\varphi(k_1, k_2) = \text{arctg} \left(\frac{Im(k_1, k_2)}{Re(k_1, k_2)} \right)$$

- ▷ **Močnostni spekter (*power spectrum*)** oz. spektralna gostota

$$P(k_1, k_2) = |\mathbb{I}(k_1, k_2)|^2 = Re^2(k_1, k_2) + Im^2(k_1, k_2)$$


2D Fourierova transformacija

(7)


Primer: Transformacija slike v Fourierov prostor




Original –
 600×800 pikslov




Frekv. spekter kot intenziteta
(log., skal. in neg. spekter)



Frekvenčni spekter –
izhodišče v (0,0)



Frekvenčni spekter –
izhodišče v (300,400)



Fazni spekter

▷ Uporabljene funkcije: `fft2()`, `fftshift()`, `abs()`, `angle()`, `log()`, `mesh()`

2D Fourierova transformacija

(8)

Kaj nosi več informacije o strukturi slike: amplituda ali faza? (vir: [3])

- ▷ Fourierova transformiranka v polarni obliki:

$$\mathbb{I}(k_1, k_2) = |\mathbb{I}(k_1, k_2)| e^{i\varphi(k_1, k_2)}$$


★ faza – relativni položaj periodične strukture v sliki.



Slika 1; $[\mathbb{I}(k_1, k_2), \varphi(k_1, k_2)]$

$$|\mathbb{I}'| = |\mathbb{I}| [U(0, 1)]^{1/2}; \varphi' = \varphi$$


$$|\mathbb{I}'| = |\mathbb{I}| [U(0, 1)]^2; \varphi' = \varphi$$



$$\varphi' = \varphi [U(0, 1)]^{1/2}; |\mathbb{I}'| = |\mathbb{I}| \quad \varphi' = \varphi [U(0, 1)]^2; |\mathbb{I}'| = |\mathbb{I}|$$

2D Fourierova transformacija

(9)




Slika 1



Slika 2



Amplituda od slike 2
faza od slike 1



Amplituda od slike 1
faza od slike 2

▷ Ugotovitev:

- ★ Faza FT nosi bistveno informacijo o strukturi slike.
- ★ **Informacija o fazi je ključna za človekovo percepcijo!**

2D Fourierova transformacija

(10)


E. Lastnosti 2D DFT [1]

1. Linearnost


$$\mathcal{F}[aI_1(m, n) + bI_2(m, n)] = a\mathbb{I}_1(k_1, k_2) + b\mathbb{I}_2(k_1, k_2)$$

2. Premik v slikovni ravnini


$$\mathcal{F}[I(m - a, n - b)] = \mathbb{I}(k_1, k_2)e^{-i2\pi(\frac{ak_1}{M} + \frac{bk_2}{N})}$$




Original (256 × 256)




Frekvenčni spekter




Fazni spekter



Po translaciji



Frekvenčni spekter



Fazni spekter

2D Fourierova transformacija


(11)

3. Premik v frekvenčni domeni


$$\mathbb{I}(k_1 - a, k_2 - b) = \mathcal{F} \left[l(m, n) e^{i2\pi(\frac{am}{M} + \frac{bn}{N})} \right]$$

4. Skaliranje


$$\mathcal{F} [l(am, bn)] = \frac{1}{|ab|} \mathbb{I}\left(\frac{k_1}{a}, \frac{k_2}{b}\right)$$




Original (256 × 256)




Frekvenčni spekter




Fazni spekter



Po skaliranju




Frekvenčni spekter




Fazni spekter

5. Rotacija


$$\mathcal{F}[\mathbb{I}(m \cos \theta + n \sin \theta, -m \sin \theta + n \cos \theta)] = \mathbb{I}(k_1 \cos \theta + k_2 \sin \theta, -k_1 \sin \theta + k_2 \cos \theta)$$




Original (256×256)




Frekvenčni spekter




Fazni spekter



Po rotaciji



Frekvenčni spekter



Fazni spekter

6. Periodičnost

- ▷ Predpostavimo, da je slikovna funkcija periodična, tj.

$$I(-m, n) = I(M - m, n) \quad \text{oz.} \quad I(m, -n) = I(m, N - n)$$

v splošnem

$$I(aM + m, bN + n) = I(m, n)$$

- ▷ potem je tudi Fourierova transformiranka periodična

$$\mathbb{I}(aM + k_1, bN + k_2) = \mathbb{I}(k_1, k_2)$$

7. Konvolucija

- ▷ V diskretnem prostoru:

$$G(m, n) = H(m, n) * I(m, n) = I(m, n) * H(m, n) = \sum_{a=0}^{M-1} \sum_{b=0}^{N-1} I(a, b) H(m-a, n-b)$$

- ▷ V frekvenčnem diskretnem prostoru:

$$G(k_1, k_2) = \mathbb{I}(k_1, k_2) \mathbb{H}(k_1, k_2)$$

★ Gre za množenje po elementih in ne za matrično množenje!


2D Fourierova transformacija

(14)

Primer:




$I(1944 \times 2592)$




$H(11 \times 11)$


Konvolucija
(diskretni
prostor)




$G(1944 \times 2592)$



$H(1944 \times 2592)$






$|I(k_1, k_2)|$



$|H(k_1, k_2)|$

Konvolucija
(frekvenčni
prostor)




$|G(k_1, k_2)|$

F. Aplikacije 2D DFT

1. Filtriranje slik

- Področja uporabe: odstranjevanje različnih vrst šuma, poudarjanje določenih lastnosti slik (npr. robov), druge operacije predobdelave slik...


Primer: Pomen frekvence




Original




Enosmerna k. – $\bar{I}$




(1 frekvenca)




(1)




(1)




(2)




(2)



(10)



(997)



(114224)

2D Fourierova transformacija

(16)


Primer: Različni filtri



Original




Nizko sito



Frek. spekter




Visoko sito



Frek. spekter




Pasovno p. sito



Frek. spekter



Križ




Frek. spekter


2. Ujemanje (iskanje) šablon in (križna) korelacija [2]

- ▷ Ujemanje oz. iskanje šablon v sliki lahko enostavno izvedemo tudi v frekvenčnem prostoru (ujemanje šablon v diskretnem prostoru, glej zapiske predavanj URVRV, poglavje 4)
- ▷ **Postopek:**
 1. $I(k_1, k_2) = \mathcal{F}[I(m, n)]$ in $H(k_1, k_2) = \mathcal{F}[H(m, n)]$
 2. $R(m, n) = \mathcal{F}^{-1}[\bar{I}(k_1, k_2)H(k_1, k_2)]$
 3. (Lokalni) maksimum v R določa položaj šablone H v sliki I .
 - ★ oznaka $\bar{I}$ označuje konjugirano kompleksno število


Primer:




Original




Frek. spekter



Šablona



Frek. spekter



Po korelaciji

- ▷ Ideja uporabna tudi pri računanju parametrov toge poravnave!

3. Merjenje orientacije in razmika periodične strukture v sliki [2]

- ▷ Naj v sliki obstaja periodična struktura, potem
 - ★ vrh v močnostnem spektru ustreza iskani periodični strukturi
 - ★ vrh je za določen radij oddaljen od izhodišča (0,0)
 - ▷ ta radij ustreza razmiku med ponovitvami periodične strukture
 - ▷ smer ustreza orientaciji periodične strukture

4. Popravljanje zamegljenih slik oz. obnavljanje slik (*image restoration*)

- ▷ Gre za popravljanje defektov med zajemom slik:
 - ★ kamera ni bila ustrezno fokusirana (*out-of-focus*)
 - ★ zameglitev slike zaradi gibanja

5. Drugo

- ▷ izločanje značilnk, kompresija slik ipd.

2D Valčna transformacija

Zakaj potrebujemo valčno transformacijo (*wavelet transformation* – *WT*)?


- ▷ FT ni primerna za analizo signalov, ki imajo časovno-spremenljivo frekvenco (**nestacionarni signali**)
 - ★ zgolj informacija, če določena frekvenčna komponenta obstaja ali ne
 - ★ ta informacija je neodvisna od tega, kje v času se komponenta pojavi
- ▷ Če potrebujemo časovno lokalizacijo spektralnih komponent, potem moramo aplicirati transformacijo, ki vrne časovno-frekvenčno predstavitev signala (*time-frequency representation*).
- ▷ Pri kratko-časovni FT (*short term Fourier transform*) signal razdelimo na kratke odseke, kjer bi naj signal bil stacionaren
 - ★ za razdelitev signala uporabljamo okensko funkcijo
 - ★ **Posledica:**
 - ▷ ne moremo točno vedeti, katere spektralne komponente obstajajo ob določenih časovnih trenutkih (princip nedoločenosti)
 - ▷ poznamo zgolj časovne intervale, v katerih obstaja določen pas frekvenc (problem ločljivosti)
 - ★ **Velja:**
 - ▷ okno neskončne dolžine $\implies$ FT
 - ▷ ozko okno $\implies$ dobra časovna ločljivost ter slaba frekvenčna ločljivost
 - ▷ široko okno $\implies$ slaba časovna ločljivost ter dobra frekvenčna ločljivost

2D Valčna transformacija

(2)

A. Valčna transformacija

- ▷ Je transformacija, ki ima bazne funkcije omejenega trajanja:
 - ★ pri FT se sinusi razširjajo v neskončnost
 - ★ pri WT pa bazne funkcije variirajo v položaju, kakor tudi v frekvenci:
 - ▷ so valovi omejenega trajanja, imenovani tudi valčki (*wavelets*)



Valova in valčka (vir: [4])

- ▷ STFT daje fiksno ločljivost pri vseh časih, med tem ko WT daje spremenljivo ločljivost, in sicer:
 - ★ višje frekvence so boljše razložene v času
 - ★ nižje frekvence pa so boljše razložene v frekvenci

2D Valčna transformacija

(3)

B. 1D Zvezna valčna transformacija

- ▷ 1D zvezna valčna transformacija (CWT) signala $x(t)$ v odvisnosti od valčka $\psi(t)$ je definirana kot

$$W_x(a, b) = \langle x, \psi_{a,b} \rangle = \int_{-\infty}^{\infty} x(t) \psi_{a,b}(t) dt$$

- ▷ kjer

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right) \quad (20)$$

pri čemer sta a in b realni števili in $a > 0$.

- ★ spremenljivka a odraža merilo (*scale*) oz. dolžino izbrane bazne funkcije.
- ★ spremenljivka b pa specificira pomik bazne funkcije vzdolž osi t .
- ★ **Na nek način velja: a ustreza frekvenci, b pa času**
 - ▷ s translacijo valčka v času je signal lokaliziran v času, s spreminjanjem a pa je lokaliziran v merilu (frekvenci).
- ▷ Vidimo: Koeficiente WT dobimo kot notranji produkt funkcije x z vsako bazno funkcijo.
- ▷ Množico valčnih baznih funkcij $\{\psi_{a,b}(t)\}$ tvorimo s translacijo in skaliranjem osnovnega valčka $\psi(t)$.

2D Valčna transformacija

(4)

Merilo

- ▷ Nizke frekvence (tj. visoka merila) ustrezajo globalni informaciji o signalu
- ▷ Visoke frekvence (tj. nizka merila) ustrezajo detajlnejši informaciji o skitem vzorcu v signalu (le-ta običajno traja kratek čas)
- ▷ V enačbi (20) je člen $\frac{1}{\sqrt{a}}$:
 - ★ uporablja se za normalizacijo energije, tj. vsak transformiran signal bo pri vsakem merilu imel enako energijo

Osnovni oz. prototipni valček $\psi(t)$:

- ▷ katerikoli pasovno-prepustni (*bandpass*) filterski impulzni odziv z ničelnim povprečjem
- ▷ s povečevanjem frekvence mora padati dovolj hitro k 0

Inverzna 1D zvezna valčna transformacija:

$$x(t) = \frac{1}{C_\psi} \int_0^\infty \int_{-\infty}^\infty W_x(a, b) \psi_{a,b}(t) db \frac{da}{a^2}$$


kjer

$$C_\psi = \int_{-\infty}^\infty \frac{|\psi(t)|}{|t|} dt$$


2D Valčna transformacija

(5)


Primer: Prototipni valčki




Mehiški klobuk



Haar



Daubechies (4)



Daubechies (9)

- ▷ Definicija CWT nakazuje:
 - ★ valčna analiza je mera podobnosti med baznimi funkcijami (valčki) in signalom
 - ★ gre za podobnost v smislu podobne frekvenčne vsebine
 - ★ koeficienti CWT ustrezajo bližini (podobnosti) signala k valčku pri določenem merilu.
- ▷ Kadar računamo CWT z diskretnimi računalniki, potem parametra a in b inkrementiramo po majhnem koraku:
 - ★ to ustreza diskretizaciji časovno-merilne ravnine
 - ★ **Diskretizirana oz. vzorčena 1D CWT ni diskretna WT!**

2D Valčna transformacija

(6)

B. 1D Diskretna valčna transformacija

- ▷ Transformacijski par:

$$\begin{aligned} c_{j,k} &= \sum_n x(n) \psi_{j,k}(n) & j &= 0, 1, \dots, \log_2(N) - 1 \\ x(n) &= \sum_j \sum_k c_{j,k} \psi_{j,k}(n) & k &= 0, 1, \dots, 2^j - 1 \end{aligned} \quad (21)$$

- ▷ $\psi_{j,k}(n)$ – množica ortonormalnih valčkov

$$\psi_{j,k}(n) = 2^{j/2} \psi(2^j n - k)$$

- ▷ $\psi(n)$ – osnovni valček

$$\psi(n) = \sum_k h_1(k) \phi(2n - k)$$

- ▷ $h_1(k)$ – enotin odziv diskretnega visokega sita

$$h_1(k) = (-1)^k h_0(-k + 1)$$

- ▷ h_0 – enotin odziv diskretnega nizkega sita (mora izpolnjevati določene pogoje!)

- ▷ $\phi(n)$ – skalirna funkcija, ki jo določimo iz h_0 kot


$$\phi(n) = \sum_k h_0(k) \phi(2n - k)$$

2D Valčna transformacija

(7)

Algoritem FWT (*fast wavelet transform herringbone algorithm*)

- ▷ DWT lahko implementiramo direktno (enačba (21)) ali s hitro valčno transformacijo FWT.
- ▷ Dolžina signala $x(n)$ mora biti potenca števila 2, tj. $N = 2^{\vartheta}$.



Algoritem FWT (vir: [4])

Razlaga za 1. nivo dekompozicije:

- ▷ Signal $x(n)$ spustimo skozi nizko sito h_0 , ki ima lomno frekvenco na polovici celotnega frekvenčnega pasu signala (f_{max} – maksimalna frekvenca v signalu).
- ▷ Signal $x(n)$ pa spustimo tudi skozi visoko sito h_1 , ki ima lomno frekvenco prav tako na polovici celotnega frekvenčnega pasu signala.
- ▷ Zaradi Shannonovega teorema o vzorčenju (Nyquistova frekvenca vzorčenja!) lahko oba dobljena signala podvzorčimo oz. decimiramo s faktorjem 2 (tj. izpustimo vsak drugi vzorec).

2D Valčna transformacija

(8)

- ▷ Rezultat tega postopka pri visokem situ h_1 vrne $\frac{N}{2}$ koeficientov DWT na 1. nivoju:
 - ★ ti koeficienti predstavljajo signal v frekvenčnem območju $[\frac{f_{max}}{2}, f_{max}]$
- ▷ Rezultat tega postopka pri nizkem situ h_0 pa vrne signal iz $\frac{N}{2}$ vzorcev, ki predstavljajo signal v območju $[0, \frac{f_{max}}{2}]$:
 - ★ ta podsignal posredujemo v 2. nivo dekompozicije, kjer opisani postopek ponovimo (filtriranje, podvzorčenje, dobimo $\frac{N}{4}$ koeficientov DWT na 2. nivoju, ki predstavljajo signal v območju $[\frac{f_{max}}{4}, \frac{f_{max}}{2}]$ ter podsignal iz $\frac{N}{4}$ vzorcev iz pasu $[0, \frac{f_{max}}{4}]$, ki ga posredujemo v 3. nivo)
- ▷ **Postopek zaključimo po $\vartheta = \log_2(N)$ nivojih dekompozicije.**
- ▷ Rezultat algoritma FWT je N koeficientov DWT, pri čemer koeficiente zlagamo od najvišjega dekompozicijskega nivoja proti najnižjemu.
- ▷ Po vsakem nivoju dekompozicije:
 - ★ časovna ločljivost se razpolovi – le polovica vzorcev še okarakterizira celoten signal,
 - ★ frekvenčna ločljivost se podvoji – pas frekvenc zaobjema le še polovico prejšnjega pasu, s čimer se nejasnost v frekvenci zreducira za polovico.
- ▷ Na podoben način pridemo do IFWT, kjer namesto podvzorčenja uporabimo nadvzorčenje (*upsampling*), dobljena podsignala pa seštejemo ter ju pošljemo na naslednji nivo rekonstrukcije.

2D Valčna transformacija

(9)

D. 2D Zvezna valčna transformacija

- ▷ Zvezna slika $\mathcal{I}(x, y)$ – funkcija dveh neodvisnih spremenljivk
- ▷ 2D zvezna valčna transformacija (2D CWT) je definirana kot

$$W_x(a, b_x, b_y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \mathcal{I}(x, y) \psi_{a, b_x, b_y}(x, y) dx dy$$

kjer

- ★ b_x in b_y specificirata translacijo v dveh dimenzijah
- ★ $\psi_{a, b_x, b_y}(x, y)$ je 2D valček definiran kot

$$\psi_{a, b_x, b_y}(x, y) = \frac{1}{|a|} \psi\left(\frac{x - b_x}{a}, \frac{y - b_y}{a}\right)$$

- ▷ Obstaja ekstaktna formula za izračun inverzne 2D CWT [4].

E. 2D Diskretna valčna transformacija

- ▷ Idejo 1D DWT enostavno posplošimo v 2D.
- ▷ 2D skalirna funkcija mora biti ločljiva (*separable*), tj. produkt dveh 1D skalirnih funkcij:

$$\phi(x, y) = \phi(x)\phi(y)$$

- ▷ Če je $\psi(x)$ pripadajoč valček, potem tvorimo tri 2D osnovne valčke:

$$\psi^{(1)}(x, y) = \phi(x) \psi(y), \quad \psi^{(2)}(x, y) = \psi(x) \phi(y), \quad \psi^{(3)}(x, y) = \psi(x) \psi(y)$$


★ nadpisana številka v oklepaju pomeni indeks in ne potence!

- ▷ Zgornji trije valčki tvorijo temelj za 2D DWT – z njimi tvorimo ortonormalno bazo:

$$\{\psi_{j,m,n}^{(l)}\} = \{2^j \psi^{(l)}(x - 2^j m, y - 2^j n)\} \quad j \geq 0, l = 1, 2, 3, m, n \in \mathbb{N}$$

Algoritem dekompozicije slike

- ▷ Sliko na vsakem nivoju transformacije razčlenimo na štiri podslike, velikosti četrtnine originalne slike:
 - ★ Vsako podsliko dobimo z notranjim produktom slike in ene od valčnih baznih slik, čemur sledi podvzorčenje v smeri x in y s faktorjem 2.



▷ Za prvi nivo (tj. $j = 1$) dobimo:

$$\begin{aligned}
 l_2^{(0)}(m, n) &= \langle l_1(x, y), \phi(x - 2m, y - 2n) \rangle \\
 l_2^{(1)}(m, n) &= \langle l_1(x, y), \psi^{(1)}(x - 2m, y - 2n) \rangle \\
 l_2^{(2)}(m, n) &= \langle l_1(x, y), \psi^{(2)}(x - 2m, y - 2n) \rangle \\
 l_2^{(3)}(m, n) &= \langle l_1(x, y), \psi^{(3)}(x - 2m, y - 2n) \rangle
 \end{aligned}$$

2D DWT: a) original, b) prvi, c) drugi in tretji nivo (vir: [4]).

2D Valčna transformacija

(12)


- ▷ V naslednjih nivojih, kjer $j > 1$, sliko $I_{2^j}^{(0)}(x, y)$ razčlenimo na enak način:
 - ★ kot rezultat dobimo štiri manjše podslike pri merilu 2^{j+1} .
- ▷ Pri vsakem merilu velja:
 - ★ $I_{2^j}^{(0)}(x, y)$ – vsebuje informacije o nizkih frekvencah iz prejšnjega nivoja
 - ★ $I_{2^j}^{(1)}(x, y)$ – vsebuje informacije o horizontalnih robovih
 - ★ $I_{2^j}^{(2)}(x, y)$ – vsebuje informacije o vertikalnih robovih
 - ★ $I_{2^j}^{(3)}(x, y)$ – vsebuje informacije o diagonalnih robovih
- ▷ Postopek dekompozicije se za sliko, velikosti $N \times N$ pikslov, zaključi v J korakih, kjer $J \leq \log_2(N)$.

Hitra implementacija 2D DWT:


- ▷ skalirne in valčne funkcije so ločljive
- ▷ dekompozicijo implementiramo z 1D konvolucijo po vrsticah oz. stolpcih ter podvzorčenjem po stolpcih oz. vrsticah (detajli v [4])
- ▷ Obstaja tudi hiter postopek za inverzno 2D DWT, s katero rekonstruiramo originalno sliko z majhno degradacijo [4].

2D Valčna transformacija

(13)



Dekompozicijski korak DWT pri hitri implementaciji (vir: [4]).




Dekompozicija DWT v frekvenčni domeni (vir: [4]).

2D Valčna transformacija

(14)


Zgled: Dekompozicija slike



Originalna slika velikosti 681×908 pikslov. Uporabljen Daubechiesov valček, reda 4. Trije nivoji dekompozicije.

2D Valčna transformacija

(15)



Podrobnosti o diagonalnih robovih na drugem nivoju dekompozicije.

F. Aplikacije 2D DWT


1. Kompresija slik

- ▷ Histogram originalne sivinske slike ima običajno poljubno obliko.
- ▷ Histogrami podslik z detajli o robovih, dobljenih z 2D DWT, pa so tipično unimodalni in simetrični okrog 0:
 - ★ To dejstvo močno poenostavi analizo statističnih lastnosti slike.
- ▷ Večina koeficientov DWT ima majhne vrednosti, zato jih lahko postavimo na 0!
- ▷ Ideja kompresije:
 1. eliminiramo koeficiente z zelo majhnimi vrednostmi ter
 2. izvedemo rekonstrukcijo
 - ★ Ideja je implementirana v JPEG 2000.

2D Valčna transformacija

(17)

Zgled: Kompresija slike



Originalna slika velikosti 681×908 pikslov. Uporabljen Daubechiesov valček, reda 4 in trije nivoji dekompozicije. Kompresija izvedena z globalnim pragom. Velikost komprimirane slike je 83 % originalne.

2. Izboljšanje (filtriranje) slik

- ▷ Velika podobnost linearnemu filtriranju v Fourierovi frekvenčni domeni.
- ▷ Postopek:
 - ★ S spreminjanjem valčnih koeficientov selektivno poudarimo zanimive komponente v sliki (na račun neželenih).

3. Luščenje značilk

4. Detektiranje skritih nezveznosti v signalu (sliki)

- ▷ Skrite nezveznosti opazimo v koeficientih DWT v višjih nivojih.

Zgled: Izboljšava slik



Originalna slika



Pri rekonstrukciji zamenjali diagonalne koeficiente
in koeficiente aproksimacije na 1. nivoju


5. Zlitje slik

- ▷ Pri postopku zlitja slik (*image fusion*) združujemo dve ali več poravnanih slik istega objekta (scene):
 - ★ Cilj: lažje interpretiranje takšne zlite slike, kot pa vsako posamezno originalno
- ▷ Slike združujemo v domeni valčne transformacije:
 - ★ združujemo na nivoju istoležnih koordinat
 - ★ uporabimo lahko različne funkcije zlitja slik
 - ★ tipične funkcije: maksimalna, minimalna oz. naključna vrednost koeficientov, koeficiente vzamemo od izbrane slike ipd.
 - ★ nad tako dobljenimi koeficienti izvedemo inverzno 2D DWT:
 - ▷ s tem rekonstruiramo zlito sliko
- ▷ **Tipična področja uporabe:**
 - ★ medicina – zlitje slik različnih modalitet iste opazovane telesne strukture (npr. slik CT in MRI)
 - ★ interpretiranje multispektralnih slik

2D Valčna transformacija

(21)

Zgled: Zlitje slik





Slika 1



Slika 2



Zlita slika

Dodatna literatura

- [1] M. Sonka, V. Hlavac, R. Boyle (1994), Image processing, analysis and machine vision, Chapman & Hall Computing, London, VB.
- [2] J.C. Russ (1995), The image processing handbook, 2. izdaja, CRC press, Boca Raton, ZDA.
- [3] B. Jahne (1993), Digital image processing: Concepts, algorithms, and scientific applications, 2. izdaja, Springer-Verlag, Heidelberg, Nemčija.
- [4] K.R. Castleman (1996), Digital image processing, Prentice Hall, New Jersey, ZDA,
- [5] R. Polikar (1996), The wavelet tutorial,
<http://users.rowan.edu/~polikar/WAVELETS/WTpart1.html>