


ALGORITMI OBDELAVE PODATKOV DALJINSKEGA ZAZNAVANJA


DOMEN MONGUS

Tradicionalni pristop OPDZ

- Spoznali smo kar nekaj tehnik za to




Tradicionalne tehnike strojnega učenja



Tehnike globokega učenja (naslavljaajo drugi predmeti)

- Združujejo oba koraka...



Semantično označevanje satelitskih slik

- PRIMER: Dejanska raba prostora
 - ▣ RAZREDI: Zazidano, njiva, travnik, gozd, vodna, ...
 - ▣ APLIKACIJE: črne gradnje, degradira območja, zaraščanje travnikov, kontrola kmetijskih subvencij,...

- Ključen izziv:
 - ▣ Spektralno prekrivanje vzorcev

Spektralno prekrivanje


- RAZLOG: Spekter odboja odvisen od vpadne svetlobe in spektralnih karakteristik materiala
- PRIMER: voda in sence ... zakaj?
- Nobene garancije, da je sta voda in sence edini problem




Tradicionalni pristop

- Razpoznavanje senc in izvedba radiometričnih korekcij
 - ▣ NPR. izvedba DMR, projekcija senc in popravki slike
- OPOMBA: Skoraj nepomembno kateri klasifikator uporabite
 - ▣ Teoretično najboljši naivni Bayes

Napake [pas 8]




Pravilne razpoznave [pas 8]





Obnašanje klasifikatorjev (Sentinel 2 pas 8)

- Spektralno prekrivanje:
 - ▣ Ne območjih prekrivanja značilk razpoznavna ni mogoče,
 - ▣ Izven območja prekrivanja je razpoznavna dobra

Odstotek napak



Odstotek pravih razpoznav



Ansambelske metode

- OSNOVNA IDEJA: Več glav več ve!
 - ▣ Učenje več klasifikatorjev
 - ▣ „Demokratsko“ glasovanje vsakega klasifikatorja
- Najbolj poznani primeri so:
 - ▣ Naključni gozd
 - ▣ (Ada)boost
 - ▣ **Bayesovo povprečenje:**
 - OSNOVNA IDEJA: Uporaba Bayesove logike za seštevanje glasov posameznih klasifikatorjev
 - KORAKI:
 - ▣ Učenje klasifikatorjev
 - ▣ Statistično vrednotenje vsakega
 - ▣ Izdelava Bayesovega klasifikatorja nad rezultati

Naključni gozd

- IDEJA: Naključno generiranje več naključnih dreves
 - ▣ Vsako drevo ima 1 glas
- Zasnovan kot „bootstrap“ algoritem:
 - ▣ Naključno vzorčenje učne množice tako, da:
 - Množica ostane enako velika
 - Vsak element vhodne učne množice se lahko pojavi 0-krat, 1-krat ali n-krat v učni množici posameznega drevesa
 - Vsaka množica ustvari svojo drevo

(Ada)boost

- IDEJA: Inkrementalno učenje ansambla tako, da je vsak nov model bolje prilagojen na napake prejšnjega
 - ▣ Še vedno ima vsak klasifikator 1 glas

- Koraki:
 - ▣ Naključna izvedba prvega modela
 - ▣ Preverjanje modela
 - Večjo verjetnost izbora vzorca damo nepravilno razpoznanim vzorcem
 - ▣ Učenje novega modela



Konstrukcija klasifikacijskih orkestroev za razpoznavo dejanske rabe tal

- Definicija pragovne vrednosti in razpoznavo z dvema klasifikatorjema

- ▣ Kako definiramo pragovno vrednost?

Klasifikator #1

Klasifikator #2





Konstrukcija klasifikacijskih orkestroev za razpoznavo dejanske rabe tal

□ Definicija pragovne vrednosti in razpoznavo z dvema klasifikatorjema

- ▣ Kako definiramo pragovno vrednost?
 - Meritev informacijskega prirastka
 - Izgradnja odločitvenega drevesa


Klasifikator #1

Klasifikator #2




Konstrukcija klasifikacijskih orkestro

- Informacijski prirastek:
 - ▣ entropija množice – utežena vsota entropij podmnožic
- (Linearna) struktura orkestra:



Klasifikacijski rezultati


- Teoretično nad učno množico vedno dosežemo 100% natančnost.
- ▣ Kaj pa nad testno?




Klasifikacijski rezultati

- Kaj je optimalno število iteracij:
 - ▣ V našem primeru se rast ustvati po 8-10 iteracij
 - ▣ Dosežemo „overfitting“

Učna množica



Testna množica



Rezultati

■ Built-Up ■ Farmland ■ Forest ■ Meadow ■ Water

